23 Suche nach häufigen Mustern (Frequent Pattern Mining)

Frequent Pattern Mining:
Gegeben Menge A von Molekülen und ein Wert p.
Gesucht alle Substrukturen, die in mindestens p% der Moleküle in A vorkommen

Support, Closed Fragment:
Der Prozentsatz von Molekülen von A, die eine Substruktur S enthalten = Support $sup_A(S)$.
Eine Substruktur S ist abgeschlossen (closed) wenn es keine Substruktur S' gibt, die S enthält und $sup_A(S) = sup_A(S')$

Contrast Pattern Mining:
Gegeben zwei Molekülmengen A und B und zwei Werte p und n.
Berechne alle Substrukturen S mit $sup_A(S) \geq p$ und $sup_B(S) \leq n$

Alg für Frequent Pattern Mining

Idee:
- → Aufzählen aller Substrukturen, Speicherung aller Einbettungen (Molekülnr)
- → Schrittweises Erweitern der Substrukturen
- → Abbruch falls der Support für eine Substruktur zu gering ist

Einbettungen: → von gefundenen Substrukturen → Vorgabe eines Startfragmentes

Datenstruktur:
- → Substruktur: als Menge von Knotennummern eines Moleküls, welches die Substruktur enthält
- → Einbettung: Vektor, der jedem Knoten der Substruktur einen Knoten im Molekül zuordnet (kann mehrfach vorkommen)

Algorithmen für Frequent Pattern Mining

Aufbau des Suchbaums:

→ Wurzel: Startfragment

→ Pro Ebene wird eine Bindung hinzugefügt

→ Zu jedem Zeitpunkt existiert eine Liste aller Einbettungen

→ Kinder der neuen Ebene werden erzeugt, in dem jede Einbettung erweitert werden.

→ Alle Einbettung werden schließl. noch so in Äquivalenzklassen eingeteilt (Äquivalenzklasse = Substruktur)

Pruning:

Laufzeit linear zur Anzahl der besuchten Kinder des Suchbaums.

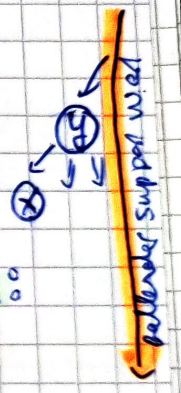

1) Positive-Support-Based Pruning

Sei y ein Vorgänger eines Kindes x im Suchbaum, $frag(y)$ die zugehörige Substruktur, $sup_A(y)$ sein positiver Support-Wert, dann:

→ $frag(y)$ ist ein Teilgraph von $frag(x)$

→ $sup_A(y) \geq sup_A(x)$

⇒ Support-Werte fallen von Ebene zu Ebene.

Gilt $sup_A(y) \leq p$, so ~~dann~~ gilt auch für Nachfolge von y

↳ Analog fällt auch der negative Support $sup_B(y)$, da $sup_B \leq n$ gelten muss, kann der negative Support nicht zum Pruning verwendet werden

2) Size-based Pruning

Analog können Vorgaben an die maximale Größe eines Pattern zum Pruning eingesetzt werden.

CIW

Alg für Frequent Pattern Mining

Pruning:

3) Smallest-fulfilling-Pattern Pruning:
Werden nur die kleinsten Pattern gesucht, die die Support-Wede erfüllen, dann Teilbäume unter Treffern abgeschnitten werden.
Abgeschlossenheit kann nicht zum Pruning verwendet werden

4) Structural Pruning
Seien y und x Knoten des Suchbaums, y wird vor x bearbeitet. Der Teilbaum unter x kann abgeschnitten werden, falls $frag(y) = frag(x)$

Detektion struktureller Gleichheit:
(USHILES)
Generiere eine kanonische Darstellung des Patterns und vergleiche mit allen bereits processierten Pattern

Vermeidung von Substruktur-Duplikaten

Atome erhalten eine aufsteigende Nummer nach Einfügereihenfolge = Atom-Ordnungsnummer

1) Erweitere stets nur an Atomen, deren Ordnungsnummer ≥ der Ordnungsnummer des Atoms ist, an dem zuletzt hinzugefügt wurde.

2) Definiere eine Ordng < auf ausgehende Bindungen an einem Atom, erweitere nur nach aufsteigender <-Ordng:
   1) Einfach < aromatisch < Doppel < Dreifach-bindg
   2) Ringschluss bindungen (führen zu Atomen der Substruktur) < Offene Bindg (neue Atome)
   3) Ordnungszahl Zielatom HL...

3) Verbiete Ringschlussbindungen von Atomen mit hoher Ordnungsnummer zu Atomen mit kleinerer Ordnungsnummer

CW

Alg für Frequent Pattern Mining

Hinweise Structural Pruning:

→ Approximation: Es werden alle möglichen Substrukturen betrachtet, Es können Duplicate immernoch auftreten

→ Erweiterungen: Symmetrische Moleküle führen zu Kindern eines Knotens im Suchbaum, die sich nur durch die Atom-Ordnungsnum unterscheiden

→ Equivalent Sibling Pruning:

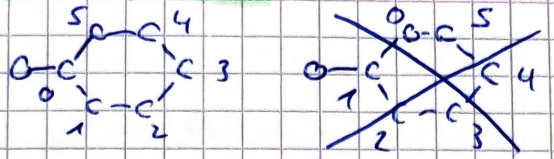

→ Perfect Extension Pruning: → Kannst sich eine Substruktur in allen Einbettungen in gleicher Weise vergrößern, so ist keine Verwerfung notwendig, bis die maximale, gemeinsame Teilstruktur erfasst ist
→ Alle werden dies enthalten

Initiale Einbettung:

→ Starte mit gemeinsamer Konstruktur Σ:

↳ Vor der eigentlichen Suche müssen alle Einbettungen von Σ gefunden werden.

↳ Substitutionssuche:

↳ Kann mit MOSS-Alg: Eingabe: Σ und ein Molekül, p = 100 %

↳ Oder VF2

→ Starten ohne Vorgaben (kein initiales Mapping)

↳ Wurzel des Suchbaums: leere Struktur

↳ Ebene 1: Alle vorkommenden Elemente sortiert nach Häufigkeit

↳ Folgene-Ebene: Betrachte nur noch Kanten für Atome deren Element in den Vorgänger-Teilbaum auf Ebene 1 nicht betrachtet wurde

Alg für Frequent Pattern Mining

Erweiterungen:

Kantrast-Muster:

-> Kontrast-Muster mit gleichem Alg, der negative Support wird für alle resultierenden Pattern überprüft

-> Negativer Support nicht für Pruning

-> Suche wird beschleunigt, wenn auch für die Negative-Menge B alle Mappings kontinuierlich berechnet und erweitert werden.

Ring-Matching:

-> Molekühle mit vielen Ringen führen zu sehr hohen Laufzeiten

-> Identifiziere alle S/G-Ringe und matche diese nur als Einheit

Variable Kettenlänge:

-> Analog zum Ring-Matching können variable Länge Kohlenstoff-Ketten einander zugeordnet werden.

CIW – CL 4

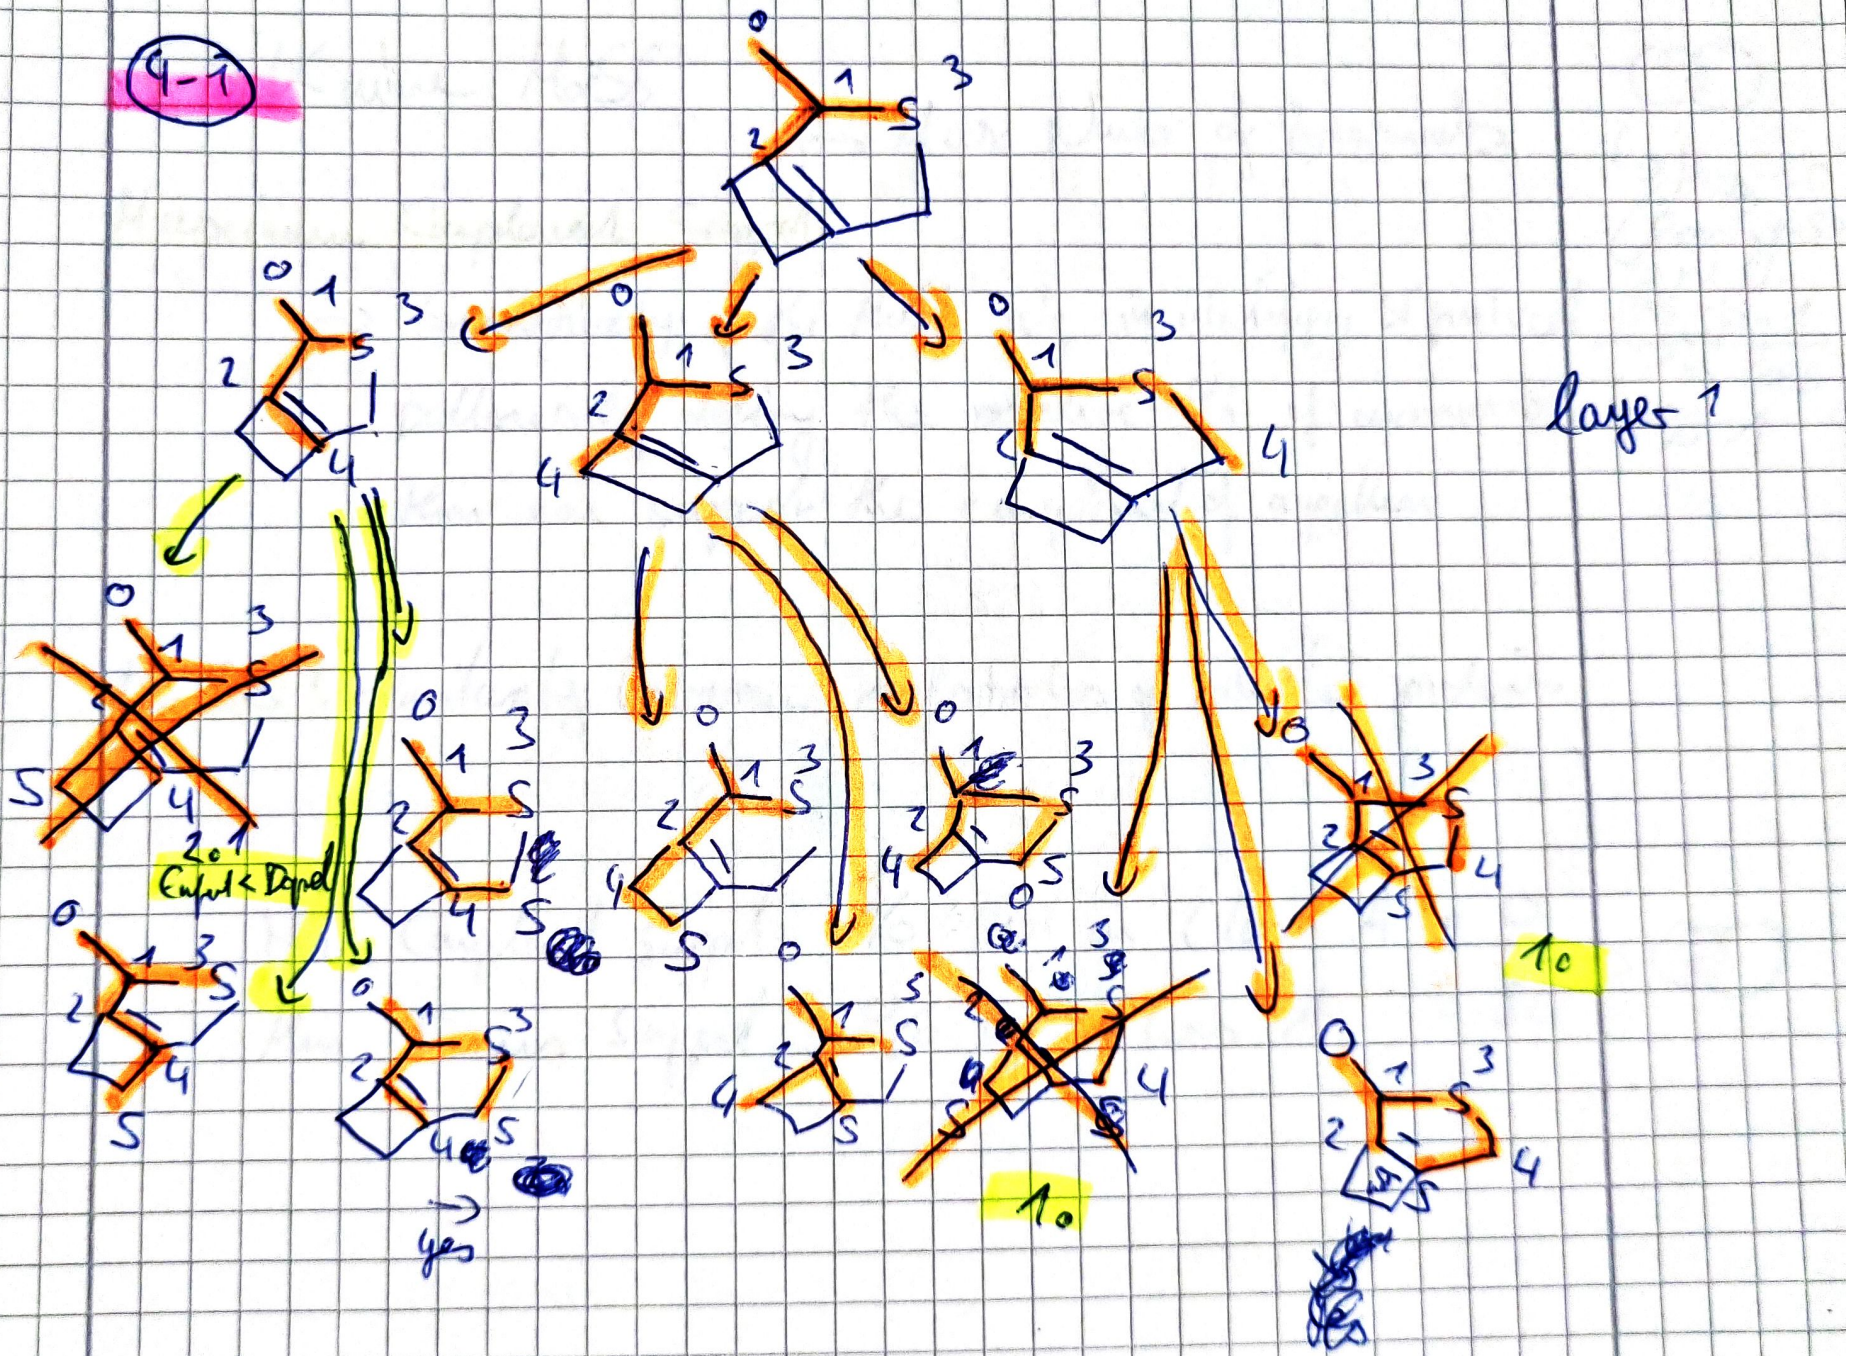

CIW - Ex 4

(4.2) Kmine MoSS

↳ Max Number of fragments

Maximum Complement Support:

→ Sensitivity of the MoSS alg in identifying significant patterns by defining the relative % of instances that can support the complement of a pattern

↳ Max = 0
Focus Supp = 50
not in 0% class 1
→ in class 50% 1

MoSS: similarity between substrates of similar proteins

Max Complement Support % not in Class A = 0
Min Focus Support % in Class A = 50 →

CIW

2.4 Generierung von Strukturdiagrammen

Structure Diagram Generation = SDG

geg: Molekülgraph $G = (V, E)$ mit chem. Annotation

ges: Layout des Graphen $f: V \to \mathbb{R}^2$ nach chemischen Regeln

eg: Grafische Regeln Strukturdarstellung:

→ Bindungen: Linien gleicher Länge

→ Atome: Winkelverteilungsregeln

→ Zeichnen auf Waben

SDG ist NP-schwer

→ IUPAC: Bindg: gleiche Länge, Azyklische Atome: Winkel vielfache von 30°/45°, Ketten: Zick Zack rel Waagerecht, Ringe ist $R \leq 8$: regelmäßige Polygone $\phi = 180° - 360°/R$,

Ringsystem: Waagerecht, Elementsymbole: C rel davon H nicht

↳ Spezielle regeln für natürlich vorkommende Moleküle, eg: Aminosäuren, Zucker

↳ Platzierung von Heteroatomen in Heterozyklen, Ausrichtung funkt. Gruppe

Grundalgorithmus: (iteratives Platzieren)

```
S = select start atom from V          // S: drawing queue (*)
while (S ≠ ∅)
    s = select atom from S; draw_atom(s)          (*)
    calculate neighbor_locations(s)          // Winkelverteilungsregeln
    for (each v ∈ s.adj)
        S = S ∪ {v}
```

↳ Heuristiken zur Auswahl des nächsten zu zeichnenden Atoms in (*)

↳ Algorithmen zur Kollisionserkennung (Plane-Sweep-Verfahren)

↳ Algorithmen zur Kollisionsbehebung (lokale Veränderung des Layouts)

↳ Algorithmen zur Analyse / zum Zeichnen von Ringsystemen

CIW

Auswahl des nächsten zu zeichnenden Atoms

Priorisierung des Atome (Shelley) zur Auswahl des nächsten zu zeichnenden (Start-) Atoms

→ Minimiert Kollisionen durch frühe Platzierung von Atomen mit vielen Bindungen

→ Für jedes Atom a wird in der Iteration n ein Score $S_{a,n}$ berechnet:

$S_{a,0} = 1 + 2\,\delta$ % $\delta = 1$ if a is cyclic ; 0 if acyclic

$S_{a,n} = 3\,S_{a,n-1} + \sum_j S_{j,n-1}$ % j ranges over the atoms adjacent to a

→ Abbruch: Praxis $n = 5$ dann länge konstant

Generieren von Strukturdiagrammen

Drawing Units:

→ besseres Layout ⇒ Aufteilung des Moleküls in Drawing Units:

↳ Chain Drawing Unit (CDU): möglichst lange Kette von acyclischen Bindungen

↳ Ring Drawing Unit (RDU): zusammenhängendes Ringsystem

↳ Iterativer Alg kann auf DU's erweitert werden

Böse Sonderfälle:

→ stereochemisch eigenschützende Systeme, Bereiche hoher Dichte

→ Zeichnen von Makrozyklen

→ überbrückte Ringsysteme

→ komplexe Teile sollten weiterhin als „Prefabricated Units" abgespeichert

Zeichnen von Ringsystemen

Analytische Aufbaumethode

1) Erzeuge den Nachbarschaftsgraph
2) Berechne die Zusammenhangskomponente
3) Entferne alle Brückenkanten (α und β) aus dem Graphen
4) Erzeuge das Layout für die einzelnen Komponenten
5) Schließe die Komponenten topologisch korrekt geordnet wieder zu einem Ringsystem zusammen

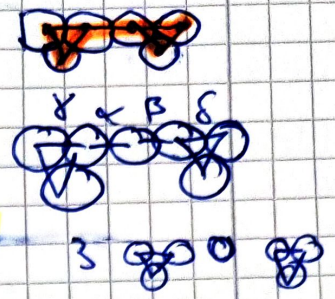

→ Einzelne Ringe mit Ringgröße $R \leq 8$ werden als regelmäßige Polygone direkt gezeichnet, wenn sie eine einzelne Bindg-Komponente bilden

→ Verwendung von Templates aus einer Ringdatenbank (RDB)

↳ nur Ringgerüst, ohne Atome und Bindungstyp — USHILES
↳ use hash-table für Zugriff
↳ Hashwerte werden aus der eindimensionalen Repräsentation des Ringsystems berechnet

→ Kraftfeld basierte Zeichenmethoden

↳ „Fallback-Methode", falls ein Ringsystem anders nicht gezeichnet werden kann
↳ qualitativ Minderwertig , cyg & Spring-Modell

Kollisionserkennung

→ Liniensegment-Schnittproblem

→ Problem:

gegeben: Menge von Liniensegmenten $s_i = (p_i, q_i)$, $i = 1, \ldots, N$

Schnittest: Schneiden beide sich?

Schnittpunktaufzählung: Bestimme alle Paare sich schneidender Segmente

→ Naiver Alg:

→ teste alle paare s_i, s_j auf Schnitt: $O(N^2)$

→ Es kann $\Omega(N^2)$ Schnitte geben

→ Scan-Line Prinzip:

→ Scan-Line speichert alle ~~nicht~~ schneidenden Liniensegmente

→ Ordnungsrelation $A \uparrow_x B$: an x-Koordinate x liegt A oberhalb von B

→ Modifikationen zur Entfernen von Kollisionen:

→ Drehen einer ganzen PFU ⊘ funktional nicht

→ Austauschen von Substituenten

→ Ändern des Winkelmusters

→ Verkürzen von terminalen Bindungen

→ Rotieren von Bindungen innerhalb einer CDU

→ Verlängern von Bindungen

→ Verändern von Bindungswinkel

⇒ Modifikationen außerhalb einer PFU sind vorteilhafter für das Gesamtlayout

CMM

Optimales Ligand Layout

Ziel: Finde eine zweidimensionale Konformation des Liganden, die eine überschneidungsfreie Anordnung der Interaktionslinien ermöglicht

→ Topologische Methode

→ Mögliche Operationen zur Beeinflussung der Konformation:

→ Flippen von Bindungen

→ Austausch von Bindungen, die von demselben Atom ausgehen

→ Chemische Regeln müssen beachtet werden, z.B. cis/trans-Regeln oder korrekte Anordnung von Stereozentren

Initiale Aminosäureplatzierung

→ Geometrische Methode

→ Basiert auf der konvexen Hülle des Liganddiagramms

↳ Schritt: Verfolgung der Bindungsrichtung

↳ Satz: Senkrecht zur benachbarten Polygonkante

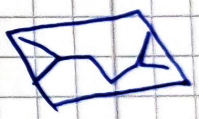

→ Platzierung der Aminosäuren unabhängig voneinander

→ Kollisionen zwischen einzelnen Elementen möglich

Kollisionsbehandlung

→ Suche nach einer optimalen relativen Anordnung aller Diagrammelemente

→ Aufzählung der Aminosäurenpositionen auf einem polaren Gitter

→ Kollisionstypen:

→ Überlappung von Strukturdiagrammen

→ Überkreuzung von Interaktionslinien

→ Überschneidungen von Interaktionslinien und Diagrammen

CW

Platzierung der Aminosäuren mit hydrophoben Kavitäten

→ Kavitätflächen des Liganden werden durch Abschnitte eines kubischen Splines um den Liganden symbolisiert

→ Stützpunkte für den kubischen Spline: Koordinaten der apolaren Schwerpunkte, um eine Standardlinienlage nach außen verlegt

→ Platzierung mit Hilfe eines Gitters

CIW

2.5 Berechnung molekularer Oberflächen

→ Van der Waals-Wechselwirkung:
↳ Dipol-Dipol / induzierter Dipol
↳ Dispersions wechselwirkung

→ Lennard-Jones Potential // Bindungsenergie

$$V_{ij}(r) = \frac{A_{ij}}{r^{12}} - \frac{B_{ij}}{r^{6}}$$

↳ A_{ij} & B_{ij} sind abhängig von Element der beteiligten Atome i,j → abstand auf welchen sich nicht gebundene Atome // Kugel in der VdW-Kräfte wirken können
↳ für Atomradien

→ Minimum: VdW-Radius der Atome

→ Aussage: Moleküle nähern sich nicht näher an

Molekulare Oberfläche

United-Atom-Radii Modell: H-Atome an C werden nicht explizit modelliert, dafür wird Radius des C vergrößert

Bedeutung Oberfläche

→ Bindung setzt Komplementarität der Oberfläche voraus

→ Modellierung: Entwurf von Molekülen mit Oberflächenkomplementarität
↳ Visualisierung ↳ Alg, Docking, Überlagern

→ Wechselwirkungsenergie hängt von Molekülobefflächen ab:
→ Übergang Dielektrizitätskonstante Protein-Solvent
→ Desolvatisierung
→ Hydrophober Effekt

CW

Oberflächentypen

→ VdW Oberfläche: Vereinigung der nicht überdeckten Oberflächen der VdW Kugeln

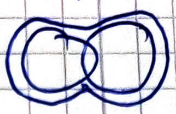

↳ sehr schmale Kavitäten ↯

→ Lösungsmittel-zugängliche Oberfläche: Lage des Zentrum einer Lösungsmittelkugel, die auf der VdW Oberfläche liegt

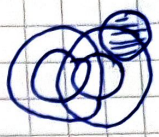

→ Molekulare Oberfläche: Abrollfläche einer Lösungsmittelkugel auf der VdW-Oberfläche

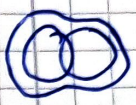

Oberflächen:

Konvex — Teilfläche einer Kugel

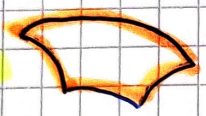

Sattelförmig

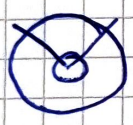

Torus

Konkav

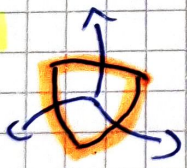

3 Begrenzungsebenen

Molekulare Oberfläche & Charakterisierung

→ Konvexe und konkave Fläche sind jeweils von Sattelflächen umgeben

→ Eckpunkte aller Flächen sind die Berührpunkte der Probe an Positionen mit 3 Berührungspunkte ⇒ diskrete Beschreibung durch Graphen möglich

→ stetig & differenzierbar

→ Problem: Selbstdurchdringung der Oberfläche:

↳ Cusp Trimming: Entfernen Solcher

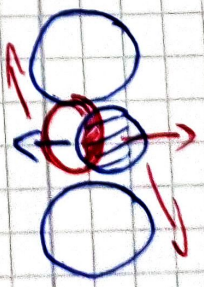

CIW

Molekulare Oberfläche, Berechnung

→ Michael Connolly

→ Diskreter Teil: Berechnung des Netzwerks der Torusbahn

→ Analytischer Teil: Berechnung der Oberflächensegmente (Kappe, Grätte, Eckpunkten)

→ Gift-Wrapping-Alg

→ Initialisierung: → suche beliebige konkave Fläche S als Startpunkt

→ speichere alle auslaufenden Torusbahnen in eine Queue Q

→ solange Q nicht leer:

→ wähle nächste offene Torusbahn b aus Q

→ berechne nächste konkave Fläche k' entlang der Torusbahn

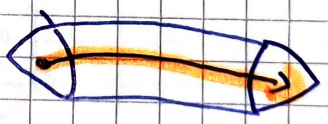

→ falls k' noch unbekannt: füge zwei neue offene Torusbahnen in Q ein

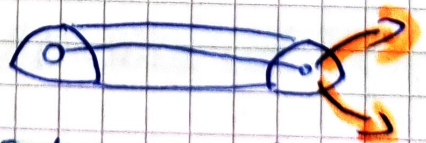

→ sonst lösche gegenläufige offene Torusbahn aus Q

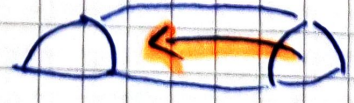

CUW

Marching Cube Alg

→ Approximation von Oberflächen aus Gitterdaten

→ Problem:

gegeben: 3D Gitter mit skalaren Werten (innen/außen) an den Gitterpunkten

gesucht: geschlossene Fläche, die die inneren von den äußeren Punkten trennt

→ Oberflächen: aus je 8 benachbarten Punkten (Würfel) wird ein korrespondierendes Oberflächensegment gebildet. Eckpunkte des Segments liegen auf Würfelkanten

15 Basismuster:

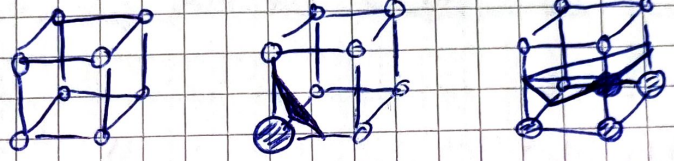

Manche innen/außen-Konfigurationen gibt es mehrere:

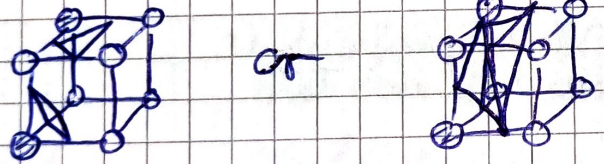

↳ Auswahl der Muster erfolgt sukzessive auf der Basis der Gitterpunkte und der Muster benachbarter Würfel

Glätten der Oberflächen durch Verschieben der Eckpunkte entlang der Würfelkante

CIW

Kohonen-Karten

→ Grundlagen, Zupan

→ Kohonen-Karten ermöglichen Projektionen unter Erhaltung lokaler Nachbarschaften

→ Basistopologie: 2D-Gitter mit zyklischen Randbedingungen (Torus)

→ App: 2D-Projektion einer 3D Molekülobefläche zur Vereinfachung von Molekülvergleichen

→ Lernphase: Ordnet jeden Punkt auf der Oberfläche einen Gitterpunkt der Kohonenkarte zu.

↳ Initial: Random

↳ Lernprozess: 1) Auswahl eines Neurons mit Zielfunktion über Eingabevektor (Koordinaten)

2) Anpassung der Gewichtsvektoren des ausgewählten Neurons und deren Nachbarn in der Karte

↳ Projektion von Oberflächeneigenschaften in die Karte

CIW – Ex-4

(4.3) Ball-Pivoting-Alg

1) **BPA:**

BPA is a surface reconstruction method used to generate triangle meshes from unorganized point cloud data.

It iteratively constructs triangles by pivoting balls of a fixed radius around the points.

The algorithm identifies neighboring points within the ball and forms triangles gradually expanding mesh

2) Family of interpolation technique
   - ↳ Rolling a ball around the underside
   - ↳ triangulation methods, mesh generation alg

3) Radius of the ball

the smaller the radius: the smaller the result, the more accurate the result, the higher level of detail

too small → overly sensitive to noise

4) edge labels:

active: initially all edges, candidates for triangles

boundary: forms part of the boundary of the reconstructed surface mesh

frozen: edge that has been used to form triangles and has no ~~edjty~~ unprocessed points left in its adjacent region.

active → boundary: when one adjacent point has no neighboring points within the point cloud (radius r)

CIW

Reduzierte Graph-Deskriptoren

3.1 Reduzierte Graphen

→ Molekülgraph als Deskriptor: → präzise
→ aber: Reine Abstraktion, schwierig Vergleichbar

→ Reduzierte Graphen:
- → Repräsentation durch Graphen mit geringerer Komplexität
- → Vorteile: Abstraktion, potenzielle einfache/effiziente Vergleichbarkeit
- → Knoten: Gruppe von kovalent gebundenen Atomen
- → Kanten: Verbinden Knoten, von denen Atome mind. zwei verbunden sind

→ Existiert als Markush-Strukturen

→ Generierung:
- → Bestimmung der SSSR, jeder SSSR-Ring wird ein Knoten:
  - ↳ Knotentyp Ar: aromatischer Ring; R: sonstiger Ring
- → Bestimmung aller exhgd. aliphatischer Kohlenstoffketten
  - ↳ terminale Ketten werden entfernt
  - ↳ Knotentyp L: Linker
- → Bestimmung der Atome mit Donor-/Akzeptorfunktionalitäten
  - ↳ Knotentyp F: Feature

Mol Graph → Reduced Graph → Daylight Fingerprint

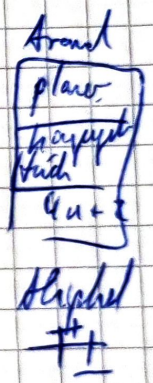

CHW

Reduced Graphs (Gillet)

Hierarchie der Knoten-Label:

Abstraktion

1) Ring / Linker / Feature
2) Aromatic Ring / Aliphatischer Ring / Linker / Feature
3) Non-hydrogen-bonding aromatic / Hydrogen-bonding aromatic / Aliphatic Ring / Linker / Feature
4) Non-hydrogen-bonding aromatic / Aromatic Ring with acceptor / Aromatic Ring with donor / Aromatic Ring with acc & donor / Linker / Donor Feature / Acc Feature / Donor & Acc Feature

Vergleich:

-> Umwandlung der reduzierten Graphen in Daylight Fingerprints

-> Fingerprint-Ähnlichkeit.

Feature Trees (Rarey)

Repräsentierung des Moleküls durch einen knotenmarkierten Baum:
- Knoten: Baugruppe des Moleküls
- Kante: gemäß Molekülgraph
- Label: sterische und chemische Eigenschaften der Gruppe

Vorteile:
- (+) bessere Repräsentierung physico-chemischer Eigenschaften
- (+) Berücksichtigung der Molekülstruktur
- (+) Vergleich basiert auf Zuordnung von Gruppen
- (+) Vergleich selbst keine exakten Subgraph-Matches nötig

1) Definition der Baugruppen
2) Zuordnung physiko-chemischer Eigenschaften
3) Entfernen jeglicher 3D-Informationen

F-Trees Generierung

→ Zerlegung der Ringsysteme:

↳ Überdeckung aller Atome mit kürzesten Zyklen:

∀ Atome a: bestimme Zyklen mit kürzester Länge, die a enthalten (DFS)

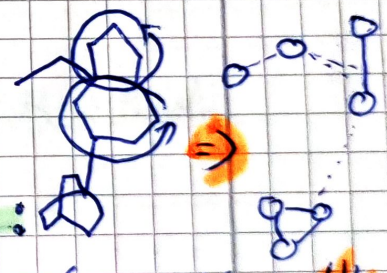

↳ Aufbau eines Zyklengraphen: Knoten: kürzeste Zyklen, Kanten: zwischen Zyklen mit shared Atoms

↳ Bestimmung der Biconnected-Komponenten (DFS), jede BCC stellt einen F-Tree Knoten dar

↳ Füge ggf. Nullknoten zur Verbindung acyclischer F-Tree Knoten ein

F-Trees Kuden Lald

Randbedingungen durch Vergleichsalgorithmen:

↳ Generator-Funktion: g: Molekülfragment → Label

↳ Compare-Funktion: f: Label × Label → $[0,1]$

↳ Combine-Funktion: c: Label × Label → Label

Sterische Eigenschaften:

→ #Atome → approx. VdW-Volumen (Kugelvolumen)

physiko-chemische Eigenschaften:

→ Atomtyp-Profil $A = (a_1 \ldots)$, a_1 = #Atome Typ 1

→ Wechselwirkungsprofil $I = (i_1 \ldots)$, i_1 = #(Ws-Partner vom Typ 1)

→ Compare Funktion:

$$f(A,B) = \frac{\sum_i \min(a_i, b_i)}{\sum_i \frac{a_i + b_i}{2}}$$

F-Trees Vergleichsalgorithmen

Berechnung eines topologie-erhaltenden Matchings M zwischen Teilbäumen zweier F-Trees:

→ jeder Knoten tritt in höchstens einem Match auf

→ sei P die Menge der Pfade, deren intermediären Knoten keinem Match angehören. Für je zwei Matches $m = (a,b)$, $m' = (a',b')$ gilt:
$\exists$ Pfad in P zwischen Knoten aus a und a' g.d.w. $\exists$ Pfad in P zwischen Knoten aus b und b'

→ Teilbäume sind in der Größe beschränkt

→ Matches sind bis auf einen Faktor f kalibriert: $\frac{1}{f} < \frac{a}{b} < f$

Ähnlichkeitswert eines Matches (a,b):

$$sim(m) = s\, f_{sterisch}(a,b) + (1-s)\, f_{chemisch}(a,b)$$

Ähnlichkeitswert zwischen zwei F-Trees A und B:

$$S_M(A,B) = \frac{\sum_{m \in M} size(m) \cdot sim(m)}{size(A) + size(B)}$$

Ex Topologieerhaltung

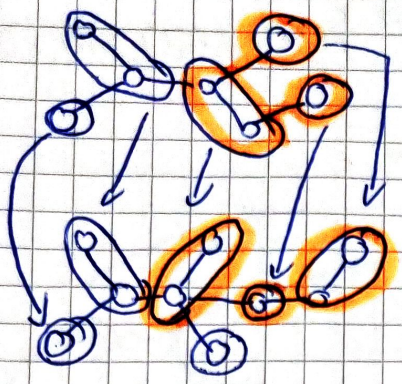

nicht topologie erhaltend

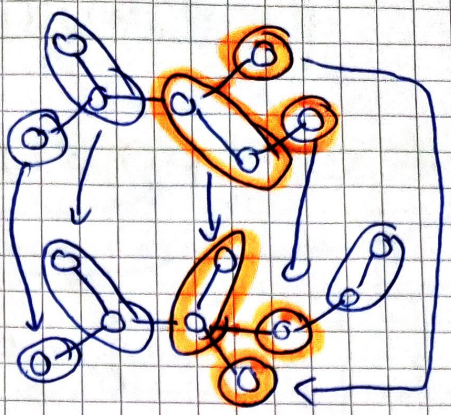

Topologie-erhaltend

F-Trees Vergleichsalgorithmen: 1. Split-Search

Def: Gegeben zwei F-Trees. Ein Split ist ein Paar von gerichteten Kanten, eine in jedem F-Tree

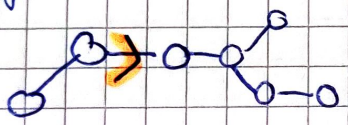

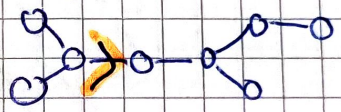

Ein Split beschreibt die Zerlegung in zwei Teilbäume und die Zuordnung der Teilbäume

Split-Search-Alg (Divide & Conquer):

→ ∀ topologie-erhaltenden Splits:
Bewerte Splits nach Ähnlichkeit der zugeordneten Teilbäume und wähle die n besten Splits aus

→ ∀ ausgewählten Splits:
Rekursive Berechnung der Ähnlichkeit der Teilbäume.
Zusammenfügen zu einem Gesamtähnlichkeitswert,
Rückgabe des besten Wertes

F-Trees : 1. Split Search

$$score(S) = \alpha \left(\frac{bal(a_1, a_2) + bal(b_1, b_2)}{2} \right) + (1-\alpha)\left(sim(a_1, b_1) \oplus sim(a_2, b_2) \right)$$

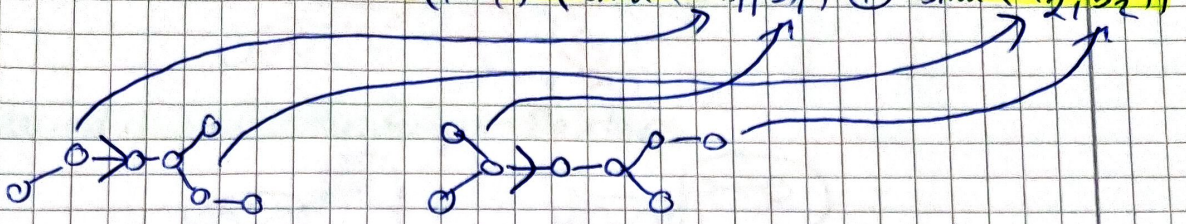

α : balance - versus - similarity factor

F-Tree Vergleichsalg: 2. Match-Search

Problem Split-Search alg erzeugt nicht-terminale partielle Matches!

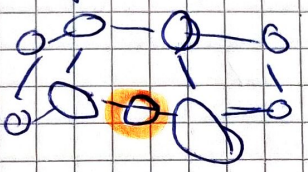

1) 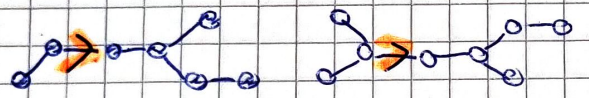
// setzen eines Initialsplits

2) 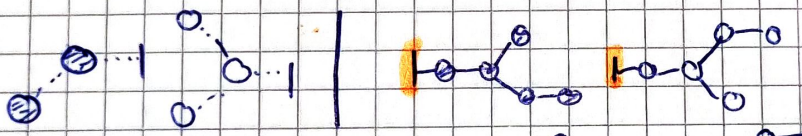
// Vergleich von Teilbäumen mit Wurzel

3) 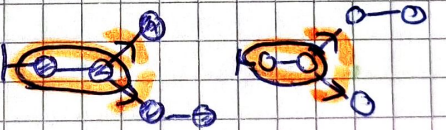
// Auswahl des besten Erweiterungs-Match

4) 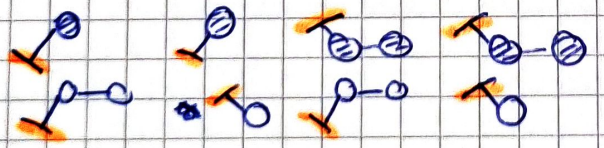
// Berechnung der Ähnlichkeit aller Teilbaumkombinationen

5) 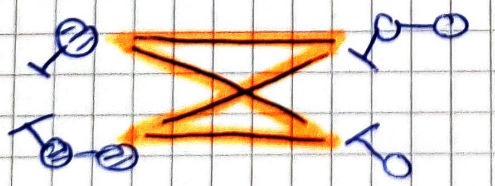
// Bestimmung der Teilbaumkombination mit höchstem Ähnlichkeitswert

Dyn. Programmierung:

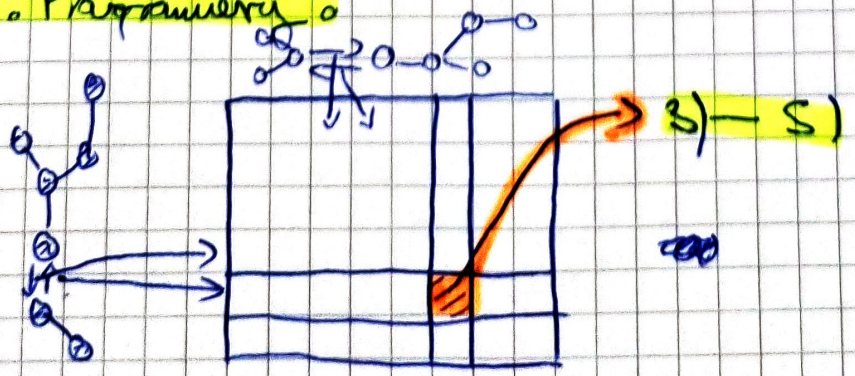

CWW

Teilalgorithmen des Match-Search

Bestimmung der Reihenfolge, in der Matrix berechnet wird

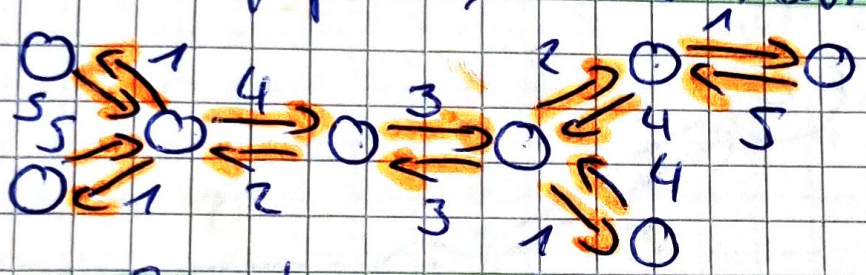

Bewertung von Erweiterungs-Matches

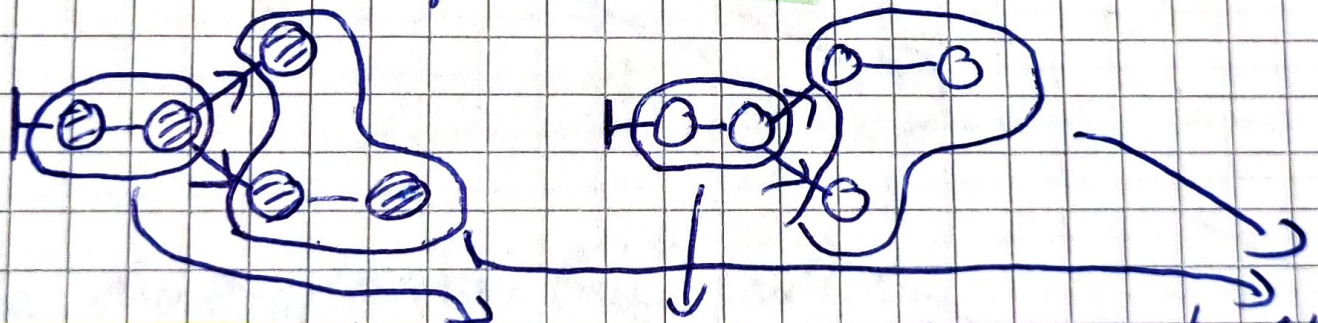

$$Score(m) = \alpha\, sim(a_1, a_2) + (1-\alpha)\, sim(V_1, V_2)$$

Bewertung der Zuordnung von Teilbäumen (Max-Weight-Bipartite Matching)

CW - 6x S

(S-1) Feature Trees

1)