3.2 Vergleich von Ähnlichkeitsmaßen & Anreicherungsfaktoren

Eingabe: Datensatz mit n Molekülen, davon gehören $|A|$ zur Klasse A

↳ sortiere Datensatz nach Ähnlichkeit zu einem Molekül $m \in A$

Anreicherungsfaktor für m bei $p\%$

$$E(m,p) = \frac{\%\text{ molecules of } m\text{'s class in first } p\% \text{ of data (A)}}{\%\text{ molecules of } m\text{'s class in the data}}$$

Gemittelte Anreicherungsfaktoren für Klasse A bei $p\%$:

$$E(A,p) = \frac{1}{|A|} \sum_{m \in A} E(m,p)$$

eg: vergleiche Anreicherungsfaktoren von 2D-Fingerprints & Split-Search

% MAEF = % of maximal achievable enrichment factor

↳ fitness averaging

CIW

Vergleich von Modellen: ROC-Kurven

Receiver Operating Characteristic (ROC)

Klassifizierung der Instanzen

		actual value: p	actual value: n	
prediction	p'	TP	FP	p'
	n'	FN	TN	N'
		P	N	

→ Vergleiche Sensitivität (Hit-Rate, TPR) mit Spezifität (TNR)

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN}$$

$$TNP = \frac{TN}{N} = \frac{TN}{TN + FP}$$

$$FPR = \frac{FP}{N} = \frac{FP}{FP + TN}$$

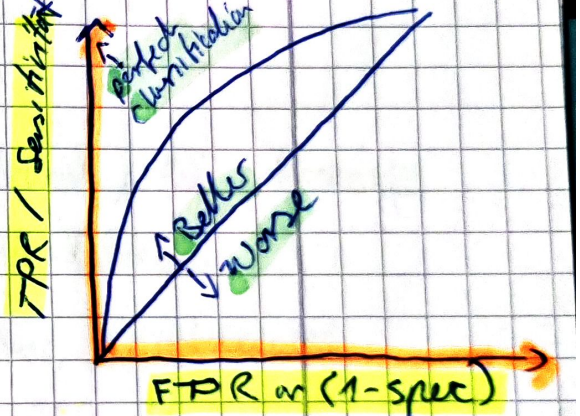

→ Genauigkeit $Acc = \frac{TP + TN}{P + N}$

→ Relative Häufigkeitsverteilung für jeden möglichen Parameterwert → klassifiziert

↳ Verschiedene Threshold t von 0 → groß und Preise werden ein

→ Optimierungsmethode

→ AUC: Werte ∈ [0,1]

Zufallsprozess: 0,5

3D-Deskriptoren

Motivation: Für die Bindung relevant ist spezifische räumliche Anordnung von funktionellen Gruppen, nicht das Bindungsgerüst.

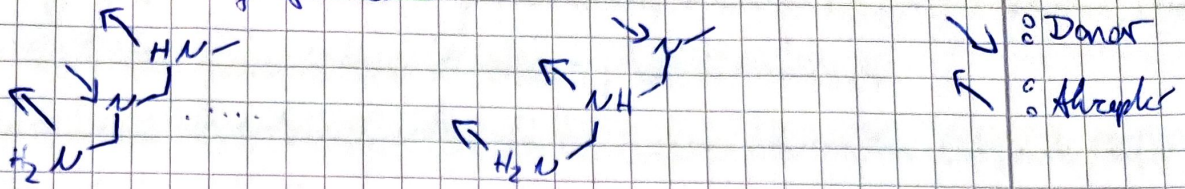

Problem: Konformation der Moleküle unbekannt

Pharmakophor-Punkte

Pharmakophor: Anordnung funkt. Gruppen im Raum, die notwendig ist, um an spezielles Protein zu binden.

↳ Ensemble sterischer und elektrischer Eigenschaften, die notwendig sind, um eine optimale supramolekulare Interaktion mit einem spezifischen biologischen Target zu gewährleisten und seine biologische Antwort zu verstärken oder zu blockieren.

Elemente: Vektoren (H-Donor, H-Akzeptor), Kugeln (hydrophobe Region), Ausschlussvolumen verbunden durch Abstandsintervalle.

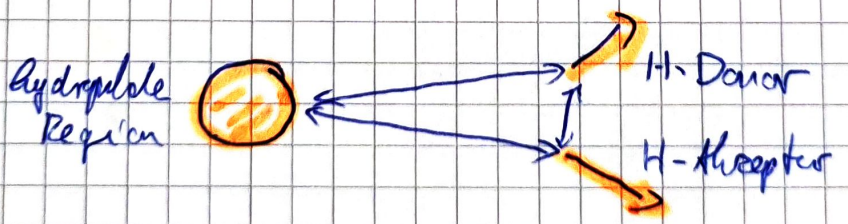

PPP (potential pharmacophoric points): Punkte, die potentiell an einem Pharmakophor beteiligt sind

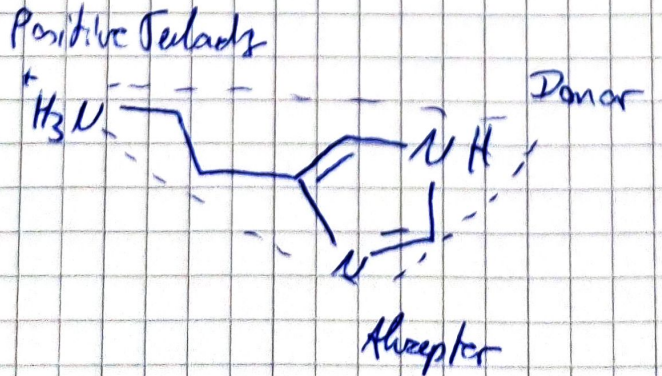

CW

Geometrische Atompaar-Deskriptoren

Starker Akz -> Schwach Akz -> N -> sch D -> stark D

Deskriptor:

- -> # Atompaare (nach Bindungseigenschaft)
- -> Array f_X speichert die Häufigkeiten auftretender [Class(i) - Distanz - Class(j)]
  - Einheiten zwischen Atomen i, j in Molekül X
- -> Distanzen werden durch Definition von Intervallen (steigende Größe) diskretisiert (Bins)
- -> Atompaare werden anhand ihrer zugeordneten

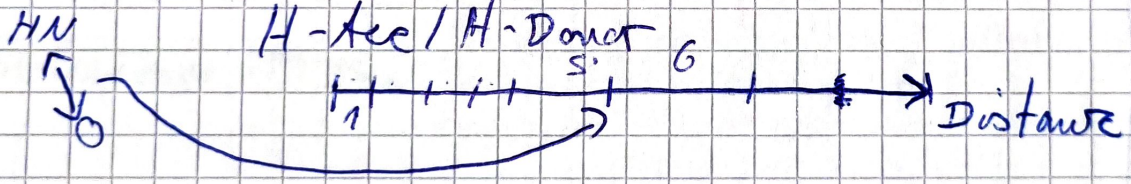

Ähnlichkeitsindex:

$$\left[\sum_{q \in \text{Bins}} \min\left(f_A[q], f_B[q]\right)\right] \Big/ \left[\frac{1}{2}\sum_{q\text{-Bins}} \left(f_A[q] + f_B[q]\right)\right]$$

3D misst Ähnlichkeit als topologische!

↳ Wir kennen Konformation nicht => Rauschen -> welche Paare

↳ Bias in Daten zu topologisch ähnlichen Molekülen

CIW

Atom-Triplet-Deskriptoren

Statt Paare werden Atom/PPP-Triplets verwendet,

Indizes sind, z.B.

↳ Für Histogramm → sortiert Liste der Dreiecksnormalen
→ Umfang, Umkreis, Fläche

Behandlung des Konformationsproblems:

→ DB mit mehreren Konformationen pro Molekül

→ Deskriptor mischt Einträge für verschiedene Konformationen // Fusion

Genauere Beschreibung von molekularer Ähnlichkeit setzt strukturelle Überlagerung voraus.

USR: Ultrafast Shape Recognition

Ballester

Referenzpunkte zur Formbeschreibung:
- → Zentroid der Datenmenge (ctd)
- → Atom mit kürzester Distanz zum Zentroid (cst)
- → Atom mit weitester Distanz zum Zentroid (fct)
- → Atom mit weitester Distanz zu fct (ftf)

Formbeschreibung durch Distanzverteilung zu Referenzpunkten:
- → Je eine Verteilungsfunktion f_p für Atomabstände zu den 4 Referenzpunkten: $f_{ctd}()$, $f_{ctd}()$, $f_{fct}()$, $f_{ftf}()$
- → Verwende die ersten drei Momente jeder Funktion $f_p()$
  - ↳ k-tes Moment:

$$m_k(f_p) = \int_{-\infty}^{\infty} x^k f_p(x)\,dx$$

↳ $S(M_A, M_B) \rightarrow [0, 1)$

Alternative Distanzhistogramme: Shape Signatures

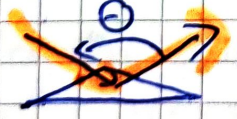

Berechne eine Strahlen-Sequenz mit randomisiertem Startpunkt, k-Reflektionen

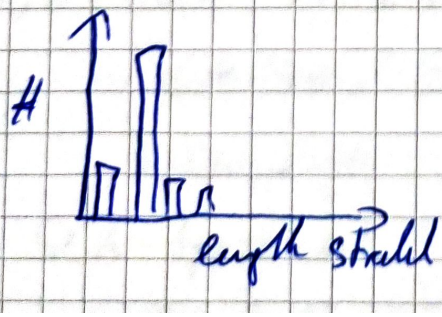

3.4

Weitere Deskriptoren

Autokorrelationsvektoren:

→ räumliche Autokorrelation: Beschreibt Wahrscheinlichkeit, dass eine Eigenschaft in der Nachbarschaft mehrmals auftritt

→ Auf Molekülstrukturen: $A(d) = \sum d_{ij}\, p_i\, p_j$

$d_{ij} = 1$, falls Bindungsabstand zwischen Atom i & j d ist

p_i = Atomeigenschaft von Atom i

→ Autokorrelationsvektor: $(A(1), A(2), \ldots, A(n))$

→ Idee: ähnliche Moleküle haben ähnliche Nachbarschafts-verhältnisse zwischen Eigenschaften, die für die Bindung relevant sind

Affinitätsfingerprints:

→ Idee: Moleküle mit ähnlichen Bindungsverhalten zu einer Referenzmenge von Proteinen sind ähnlich

→ Deskriptor: Bindungsaffinitäten eines Moleküls zu einem Protein-Panel

$P1, \ldots$: $(a1, \ldots, \ldots)$

→ Abstandsmaß: euklidische Distanz zwischen Affinitätsvektoren

→ „in-silico" Affinitätsfingerprints:

↳ statt Messung wird die Affinität mit einem Docking-Programm vorhergesagt

→ SEA-Approach:

↳ Target Identifikation über molekulare Ähnlichkeit von Liganden

Problem: Deskriptor muss experimentell bestimmt werden

CIW

3.S

Clustering von Molekülen

Alg's: Eucl. Dist., Cluster Analysis

Clustering:

→ Gruppierung einer Datenmenge gemäß eines Ähnlichkeitsmaßes

→ Verfahren des unsupervised Learnings: Erkennung von gem. Eigenschaften ohne explizite Trainingsmengen

→ supervised learning: labeled mit Trainingsmenge

App: Auswahl von Mols, um die DB erweitert werden soll
Auswahl von Mol's zum Screening
Analyse von Screening Data

Cluster - Alg

hierarchisch: → Aufbau einer Baumstruktur (Dendogram) über der Datenmenge

→ agglomerativ: Aufbau durch sukzessives Vereinigen von Clustern

→ divisiv: durch sukzessives Teilen von Clustern // schlechter meistens ↳ parallelisierbar

Ziele zwischen 5 bis 20 Cluster

nicht-hierarchisch:

→ Optimierungsprobleme (Zielfunktion min. Intra-Cluster Abstand oder max. Inter-Cluster Abstand)

CIW

Hierarchisches agglomeratives Clustering

→ Input: Menge von Objekten M; Abstandsmaß $f: M \times M \to \mathbb{R}^+$;
Abstandsmaß über Teilmengen $f': 2^M \times 2^M \to \mathbb{R}^+$

→ Output: Dendogramm über M

→ Alg:

```
C = {{x} | x ∈ M}        // Singletons
while (|C| > 1)
    select a,b ∈ C minimizing f'(a,b)
    C = (C \ {a,b}) ∪ {a ∪ b}
```

→ f' ist unterschied zw Cluster Alg

→ eg:

a) single-linkage / nearest neighbor: $f'(A,B) = \min_{a \in A, b \in B} f(a,b)$

b) complete linkage / furthest neighbor: $f'(A,B) = \max_{a \in A, b \in B} f(a,b)$

c) group average: $f'(A,B) = \frac{1}{|A||B|} \sum_{a \in A} \sum_{b \in B} f(a,b)$

d) centroid cluster analysis: $f'(A,B) = f(c(A), c(B))$

↳ Obj müssen geometrisch interpretierbar sein $c(A) = \frac{1}{|A|} \sum_{a \in A} a$

a)

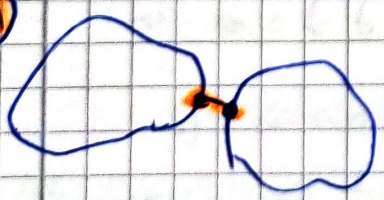

b)

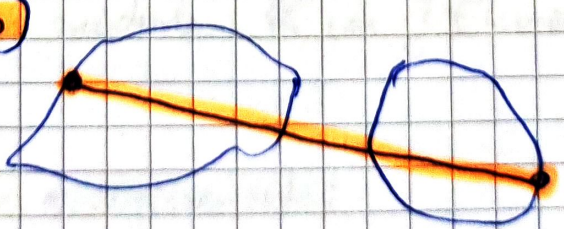

c)

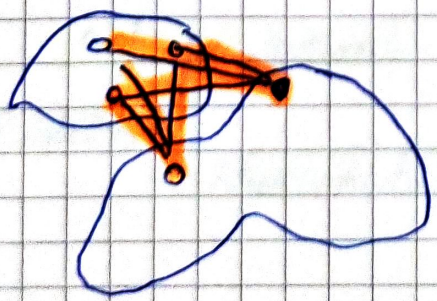

d)

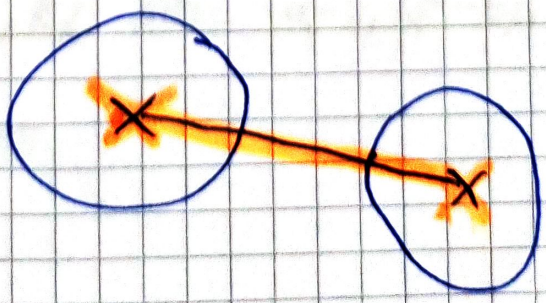

CLW

Hierarchisches agglomeratives Clustering

Ward's Methode:

→ Informationsverlust durch Clustering C wird durch eine Fehlerfunktion (Error Sum of Squares) beschrieben:

$$ESS(C) = \sum_{a \in M} (a - c(C_a))^2$$

→ Min des Informationsverlusts: $f'(A,B) = ESS((C \setminus \{A,B\}) \cup \{A \cup B\})$ ↳ Menge mit a

Lance & Williams:

→ allgemeine Rekursionsformel von f':

$$f'(C, A \cup B) = \alpha_A f'(C,A) + \alpha_B f'(C,B) + \beta f'(A,B) + \gamma |f'(C,A) - f'(C,B)|$$

eg: $\alpha_A = \alpha_B = 1/2, \beta = 0, \gamma = -1/2$ → nearest neighbor

$\alpha_A = \alpha_B = 1/2, \beta = 0, \gamma = 1/2$ → farthest neighbor

→ Übergang NN → FN

Jarvis-Patrick Clustering

1) Berechne nächste Nachbarliste der Länge J für jedes Molekül der DB
2) Zwei Moleküle a, b sind im gleichen Cluster wenn:
   - → a ist in der NN-Liste von b
   - → b ist in der NN-Liste von a
   - → a & b haben mindestens K von J Elementen der NN-Liste gemeinsam

Kriterium wird transitiv angewendet:

a k c, wenn $b_1, \dots, b_k$ mit $a - b_1, b_1 - b_{i+1}, b_k - c$

Ähnlichkeit:

Nur Ähnlichkeit > T

CIW

K-means Clustering

initial N Objekte K Cluster

→ basiert auf lokaler Optimierung

→ K-means:

- Berechne für jeden Cluster einen Mittelwert → basiert auf Cluster-Güteberechnung
- Ordne jedes Objekt dem Cluster mit ähnlichstem Mittelwert zu

→ Problem: # Cluster - k, initial Zuordnung, Optimierungsverfahren

I) Pick k, number of clusters

II) Select k data points as cluster centers (centroid) = $C = c_1, \ldots, c_k$

III) Distance between each point and the centroid

$$\text{or } dist(C_i, x)^2$$

IV) assigned data point to ~~cluster~~ closest centroid

VI) update centroids $c_i = \frac{1}{|S_i|} \sum_{x_i \in S_i} x_i$

zurück Hierarisch

CW

(5-2) Clustering

1)

Partitian Clustering

→ Dividing Dataset into distinct groups based on similarity/ distance measures

→ each point exactly to one cluster

(+) Simple

(+) Scalability

(+) Flexibility

(-) Sensitivity to initial conditions

(-) Difficult to determine the # clusters

(-) Unable to handle overlapping clusters

↳ used when # clusters is known

Hierarchical Clustering

→ organizes data points into a hierarchy of nested clusters forming a tree-like structure

→ bottom-up or ∅ top-down

(+) No need to know # clusters

(+) Capturing complex relationships

(+) Visualization

(-) Complex

(-) Lack of scalability

(-) Difficult to interpret large dendograms

↳ # clusters unknown

↳ Single Linkage: $f'(A,B) = \min_{a \in A, b \in B} f(a,b)$

Complete linkage: $f'(A,B) = \max_{a \in A, b \in B} f(a,b)$

Average linkage: $f'(A,B) = \frac{1}{|A||B|} \sum_{a \in A, b \in B} f(a,b)$

CUU

4. Strukturelle Überlagerung von Molekülen

Einführung / Starre Überlagerung

Überlagerungsproblem:

geg: mehrere Liganden, die an ein Protein binden, für das keine 3D-Struktur bekannt ist

ges: Relativorientierung der Liganden respektive des Zielproteins

Vorgehen: Überlagerung der Moleküle, so dass möglichst viele für die Bindung relevanten Eigenschaften zur Deckung gebracht werden:
↳ Volumen, H-Brücken, Hydrophobizität, Elektrostatik

→ überlagere Liganden!

Problemvariablen: Berücksichtigung der Konformationsfreiheitsgrade (flexible/rigide)
Multiple Moleküle vs Molekülpaare

Probleme:
- Konformationen der Moleküle unbekannt
- Moleküle überlagern nur partiell bei der Bindung
- Relevante Gruppen / Eigenschaften unbekannt
- Komplexes Optimierungsproblem

App: Ableiten von Pharmakophoren aus DB-Suche,
Direkte Suche nach ähnlichen Mol's,
Design von Struktur-Wirkungsbeziehungen (SAR, QSAR),
Auswertung HTS-Daten

CW

Modellierung durch Gaußfunktion

allgemeines Konzept zur Modellierung verschiedener Mol-Eigenschaften, einfache Handhabung

→ Gaußfunktion: $f(x) = a e^{-b(x-x_0)^2}$ // auf Maximalpunkt // Volumen

a: Eigenschaftsfaktor, b: Weite der Glocke, x_0: Ursprung

→ Beschreibung Molekül: $\rho(x) = \sum_{\text{Atome } i} a_i e^{-b|x-x_i|^2}$

ist in Mol ↑ Dichte für Punkt x ↓

→ Integration über den Raum: $z_{AB} = \int \rho_A(x) \rho_B(x)\, dx$ // wie gut Moleküle übereinander liegen

↳ Abhängig von Translation t und Rotation R: $z_{A,B}(t,R) = \int \rho_A(x) \rho_B(Rx - t)\, dx$

↳ Optimierungsfunktion → Max ↑

normalisieren ←

→ Ähnlichkeitsmaß nach Carbó

↳ Maß für Korrelation der Eigenschaften, Intensitäten spielen geringe Rolle

$$C_{AB}(t,R) = \frac{z_{AB}(t,R)}{\sqrt{z_{AA} z_{BB}}}$$

→ Normierter Ähnlichkeitsindex (Hodgkin):

$$H_{AB}(t,R) = \frac{2 z_{AB}(t,R)}{z_{AA} + z_{BB}}$$

Optimierung t R nur z_{AB} Optimator

→ Ähnlichkeit auf Gaußfunktion:

$$z_{AB}(t,R) = \int \sum_{\text{Atome } i,j} a_i e^{-b|x-x_i|^2} a_j e^{-b|y-y_j|^2} dx \quad ; y_j = Rx_j - t$$

→ Nach Integration: // real

$$z_{AB}(t,R) = \sqrt{\frac{\pi}{2b}} \sum_{\text{Atome } i,j} a_i a_j e^{-\frac{b}{2}|x_i - y_j|^2} = C S_{AB}(t,R)$$

↳ Zielfunktion

→ Modellierung verschiedener Eigenschaften

$$w_{ij} = \sum_{\text{Eigenschaften } p} k_p a_{ip} a_{jp}$$

↳ nur einmal e-Funktion auswerten, Raum nicht verrechnen

k_p: Gewicht der Eigenschaft

→ kein Matching zwischen funktionellen Gruppen notwendig

↳ Rein Numerisch

CIW

Starre Überlagerung (SEAL)

SEAL:

Vereinfachung: Molekülkonformationen werden als konstant und gegeben angenommen

Modellierung des sterischen und elektrostat. Feldes

Zielfunktion: Überlagerung von Gauß-Funktionen zum Molekülvergleich normiert (Hodgkin) $S_{AB}(t, \Omega)$

Freiheitsgerade:

Translation: Vektor t,

Rotation: Quaternion $Q = (q_1, q_2, q_3, q_4)$

(kleine Singularitäten)

Zufällige Startorientierungen, dann lokale Optimierung

↳ zweite Ableitg analytisch lösbar

2. Räumliche Strukturen

Strukturerzeugung:

Gegeben die Topologie eines Moleküls, können wir eine sinnvolle räumliche Molekül-Struktur berechnen?

↳ Struktur mit niedrigster bzw. sehr kleiner Konformationsenergie

Konstitution:

Menge und Art der Bindung zwischen Atomen des Moleküls

Konfiguration:

Räumliche Anordnung der Atome eines Moleküls ohne Berücksichtigung der Torsionswinkel an Einfachbindung

cis/trans E/Z // L/R

Konformation:

Räumliche Anordnung der Atome eines Moleküls (Festlegung aller Torsionswinkel)

Isomerie:

Moleküle mit gleicher Summenformel und Masse, die sich aber in der Konstitution, Konfiguration und Konformation unterscheiden können

Geometrische Parameter:

Konformation / Konfiguration

↳ Bindungslängen: Abstand zweier kovalent gebundener Atome

↳ Bindungswinkel: Winkel zwischen zwei Bindungen an einem Zentralatom $0° - 180°$

Konformation

Torsionswinkel:

Winkel zwischen zwei Flächen X-A-B und A-B-Y, die durch kovalent gebundene Atome X-A-B-Y aufgespannt werden

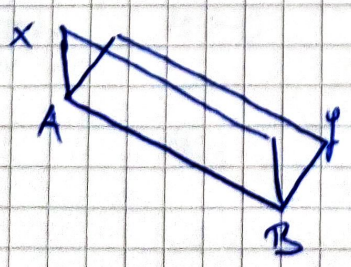

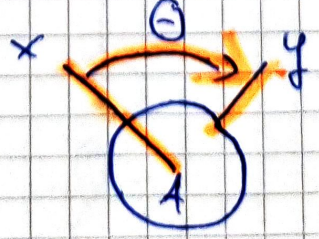

Molekülgeometrie: VSEPR-Modell

VSEPR: Valence Shell Electron Pair Repulsion

↳ **Idee:**
- Molekülgeometrie wird primär durch die Anordnung der Elektronenpaare um ein Zentralatom bestimmt
  - => freie Elektronenpaare haben genau wie bindende Elektronenpaare einen großen Einfluss auf die Geometrie
- Elektronenpaare nehmen eine geometrische Anordnung mit maximal möglichen paarweisen Abstand zueinander ein

Physikalische Grundlage:
- → e^- mit gleichem Spin haben sich mit geringer Wahrscheinlichkeit in räumlicher Nähe auf (Pauli-Prinzip)
- → e^- mit entgegengesetztem Spin in haben diese Eigenschaft nicht (Bildung Elektronen Paare)

Geometrie wird durch die Anzahl Liganden m und Anzahl freier Elektronenpaare n bestimmt: AX_mE_n-Formen

3 E, 0 nicht bindende Paare

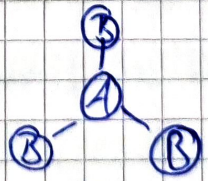

eben

2 B, 1

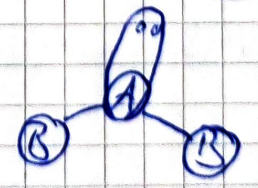

gewinkelt

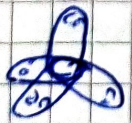

4 - 0

3 1

Molekülgeometrie: VSEPR

Gründe für Abweichungen von der Idealgeometrie:

→ Domänen freier Elektronenpaaren sind größer als Domänen von gebundenen Elektronenpaaren. Die Form ist nicht sphärisch, die Domänen haben recht großen Öffnungswinkel

→ Die Größe der Domänen von gebundenen Elektronenpaaren wird durch die Elektronegativität der gebundenen Atome beeinflusst:

steigende EN des Liganden => sinkende Größe der Domäne
sinkende EN des Zentralatoms => steigende Größe der Domäne

→ Ungebundene Atome mit vollen Elektronenschalen stoßen sich ab. Atomen kann ein Radius zugeordnet werden, aus dem sich eine Mindestdistanz ableiten lässt. Radius hängt von der EN des Atoms ab

(LCP-Modell, ligand close packing)

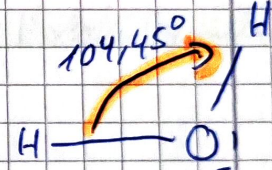

Bindungslängen

Atomradien:

Unter Annahme von Additivität lässt sich ein Internuklearabstand zwischen zwei Atomen d_{ab} durch atomspezifische Radien r_a, r_b approximieren

↳ Kovalenter Atomradius: Summe nähert die Bindungslänge an (Bindungstyp, Ion, etc)

Bindungswinkel:

Abweichung durch Repulsion großer Liganden

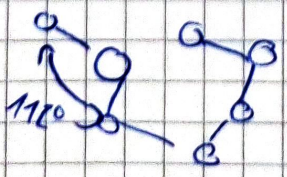

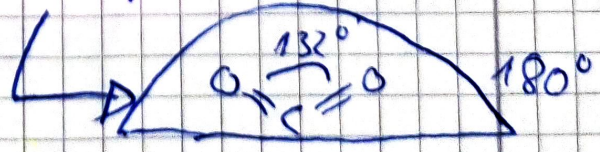

mit falscher Atomtypisierung

CIW

Weitere Geometrieparameter

Planarität an Doppel- und Amidbindungen

Doppelbindung → 0° ≈ k 180°

Referenz

Primäres Amid

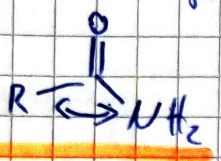

→ 0° k 180°
häufig

Sekundäres Amid

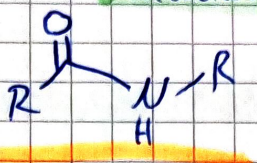

→ 0° k 180°
häufig

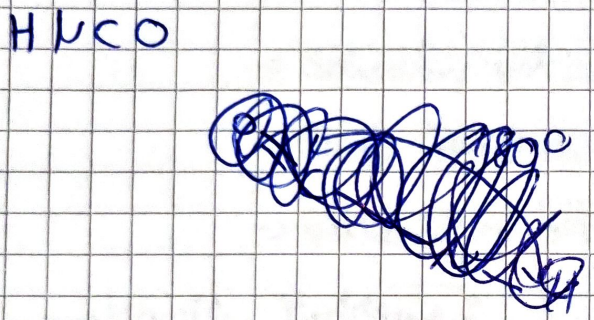

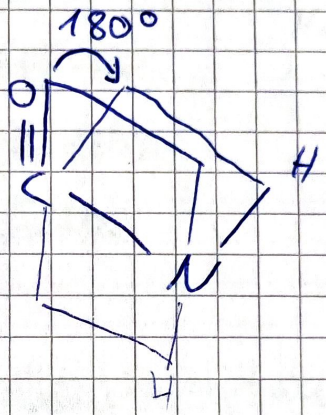

Fazit:

VSEPR/LCP-Modell beschreiben lokale Molekülgeometrie qualitativ oder gut.

Molekülgeometrien werden durch viele Eigenschaften, insbesondere durch die Repulsion großer Molekülteile und durch Delokalisation beeinflusst.

CIW

2.1 Konformationsgenerierung

Ziel:
- → Konvertierung eines Molekülgraphen in eine niederenergetische Konformation
- → Erzeugung von 3D-Koordinaten (Cartesische Koordinaten)

Anforderung:
- → Viele unterschiedliche Elemente
- → Korrekte Stereochemie
- → Schnell und automatisiert
- → Hohe Qualität der Modelle
- → Hohe Konvertierungsrate

3D-Bilder
- Manual
- Auto
  - numerical
  - Rule Based
  - Distance Based

Konzeptionelle Probleme:
- → Bindungslängen und -winkel haben ein globales Minimum, optimale Werte bekannt (VSEPR), aber
- → drehbare Bindungen haben mehrere Torsionswinkel als lokale Minima
- → Ringschlüsse erzeugen komplexe, geometrische Randbedingungen

Datengebundene Konformationsgenerierung

Regelbasiert: Input aus Kristalldaten: Bindungslänge + -winkel
CORINA

Daten/Fragment basierte: Datenbank mit 3D Koordinaten verschiedener Fragmente

A + B + C → Mole-3D

OMEGA
COSMOS

CORINA

→ Zerlegung des Moleküls:

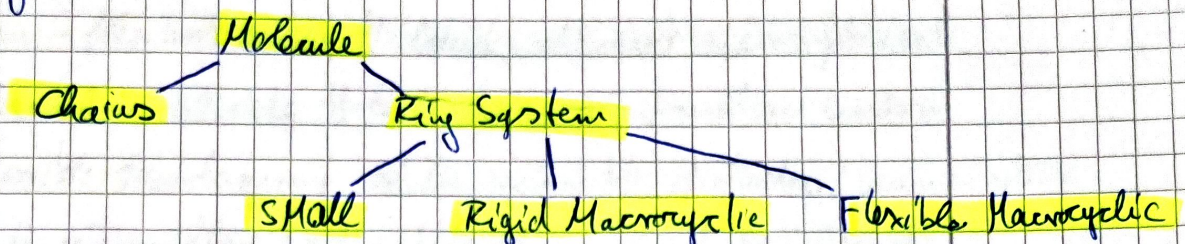

Bindungslängen und -winkel von aryliden Molekülteilen werden auf Standardwerte passend zum Hybridisierungszustand gesetzt.

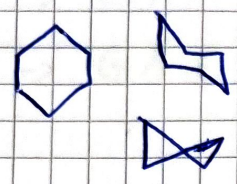

27 KJ/Mol → Für Ringe werden verschiedene
50 KJ/Mol Templates erstellt und eingesetzt.

Ringsysteme werden aus einzelnen Ringen zusammengesetzt (Baukastenprinzip: für alle Kombinationen)

Makrocyclen werden zunächst zu einer „Superstruktur" umgewandelt. Dadurch werden die einzelnen Ringkonformationen eingesetzt

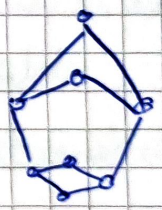

Erzeugung von Konformationsensembles

Torsionswinkelbibliotheken:

→ abgeleitet aus Kristallstrukturen kleiner, organischer Moleküle (CSD)

→ hierarchisches System von Torsionssystem

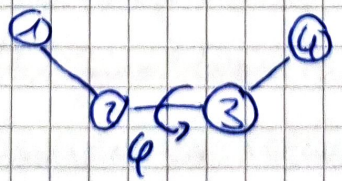

eg:

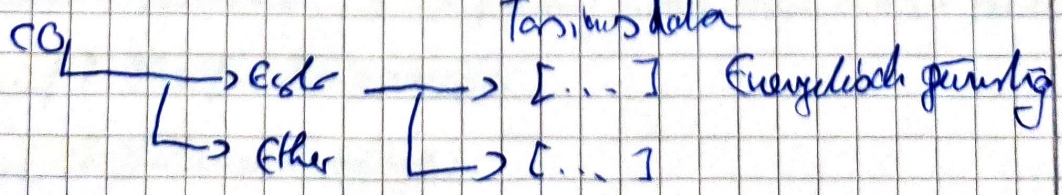

3 Flexible Überlagerung

→ Freiheitsgrade: Transformation (t, Ω) + Konformationen der Moleküle

↳ semi-flexibel: ein Molekül ist starr + eins flexibel

↳ flexibel: beide Moleküle haben Konformation ändern

↳ Flexible Überlagerung ist ein gemischt diskretes / kontinuierliches Optimierungsproblem, alle Algorithmen sind heuristisch

→ eg: Genetische Algorithmen (GA)

→ GASP

→ GA:

Lösungen	Individuen	Basismolekül ↳ zu überlagerndes Molekül
Zielfunktion	Fitness	
Repräsentation	Chromosom	
Modifikation	genetische Operatoren	

GASP

Chromosom: (Repräsentation der Moleküle) (gray-codierter Winkel)

↳ N Konformations-Strings, bestehend aus je ein Byte pro Torsionswinkel

↳ N-1 Mapping-Strings (integer): injektive Einordnung von Ww-Gruppen zu einem ausgewählten „Basismolekül" mit K Ww-Gruppen

$H_i(k) = I$: Molekül i, k-te Ww-Gruppe bildet Ww mit dem Proteln analog zu I-ten ww-Gruppe des Basismoleküls

Fitness-Funktion: (Auswertung des Chromosoms C)

↳ Aufbau der Molekülkonformationen gemäß C

↳ Überlagerung der zugeordneten Ww-Gruppen (least-square fit)

↳ Ähnlichkeitsfunktion: $S = k_1 E_{conf} + k_2 E_{vol} + k_3 E_{match}$

E_{conf}: Konformationsenergie

E_{vol}: Volumenüberlapp

E_{match}: Similarity-Score (H-Akzeptor / -Donor / aromatische Ringe)

CIW

GASP

Genetische Operatoren: (ein zufällig gewählter String wird verändert)

↳ Crossover:

→ Kanonischer-String: ein-Punkt-Crossover, zufällig gewählt

→ Mehrfach-String: zwei-Punkt-Crossover, Entfernung von doppelten Zuordnungen (Injektivität)

↳ Mutation:

→ Kanonischer-String: Mutationswahrsch. $1/L$ $(L = \#bits)$

→ Mehrfach-String: zufällig ausgewählter Integer wird auf zufällig bestimmte Zahl geändert.

Selektionsdruck: Wahrsch., dass Eltern mit besten Fit-Werten ausgewählt werden

Crossover/Mutationsraten: Wahrsch. für die Anwendung eines Operators

Insel-Modell: unabhängige Subpopulationen werden optimiert

Flexible Überlagerung

→ Flex S

→ paarweise Überlagerung, semi-flexibel

→ Ww-Modell: nicht die Ww-Gruppen der Moleküle, sondern mögliche Ww-Gegengruppen müssen überlagert werden.

↳ Def einer Ww-Fläche: Region, auf der eine Gegengruppe platziert werden muss

↳ Ww mit dem Protein kann von beiden Molekülen ausgehen, wenn sich die Ww-Flächen schneiden

Flexible Überlagerung (FlexS)

Scoring: $S = h_1 E_{match} + h_2 E_{vol} + h_3 E_{gauss}$

E_{Match}: zugeordnete Ww-Gruppen unter Berücksichtigung von geometrischen Abweichungen

E_{vol}: Volumenüberlapp

E_{gauss}: Überlapp von Gaussfunktionen: Hydrophobizität, Partialladungen, H-Brückenfähigkeit

Alg: Inkrementeller Aufbau:

1) Auswahl eines Basis-Fragments (Teil des Testliganden)
2) Unabhängige Platzierung des Basis-Fragments auf Referenz
3) Inkrementeller Aufbau des Testliganden

Basis-Platzierung:

→ Enumeration des diskreten Konformationsraums
→ Platzierung mit starrem Überlagerungsalgorithmus (RigFit)
→ Platzierung über Matching diskreter Ww-Punkte (ähnlich DockFlexX)

Aufbau:

→ Ausgehend von Basis-Platzierung
→ Solange der Testligand nicht vollständig ist
↳ Anbau eines Fragments in allen Konf. an allen Platzierungen
↳ Bewertung und Auswahl von Platzierungen mit hohem Score
↳ Clustering zur Vermeidung sehr ähnlicher Platzierungen

4 Superposition von Punktwolken

Problem:

gegeben: Menge $X = x_1, \dots, x_n$ und $Y = y_1, \dots, y_n$ von Vektoren in $\mathbb{R}^3$

gesucht: Transformation (t, Ω), die $RMSD_{x,y}(\Omega, t)$ minimiert:

$$RMSD_{x,y}(\Omega, t) = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \Omega y_i - t)^2}$$

→ zur Bestimmung von (t, Ω) ist nur Summenterm relevant

Optimierung der Translation:

→ Optimierung von Ω & t lässt sich entkoppeln:

↳ Sei Ω Rotation um Schwerpunkt $c(Y) = \frac{1}{n} \sum_i y_i$

↳ und $Y' = \Omega Y$, dann gilt:

$$R_{x,y'}(t) = \sum_i (x_i - y_i' - t)^2 = \sum_i (x_i - y_i')^2 - 2t \sum_i (x_i - y_i') + nt^2$$

$$R'_{x,y'}(t) = -2 \sum_i (x_i - y_i') + 2nt$$

$$t = \frac{1}{n} \sum_i (x_i - y_i') = c(X) - c(Y') = c(X) - c(Y)$$

Im Folgenden: $c(X) = c(Y) = 0$

↳ So verschieben, dass Massenschwerpunkte übereinander liegen!

CIW

Optimierung der Rotation (SippL)

→ SippL

→ zu optimieren: $F_{xy}(\alpha,\beta,\gamma) = \sum_i (x_i - M_z(\gamma) M_y(\beta) M_x(\alpha) y_i)^2$

→ 1) Rotation um eine Achse:

→ Drehmatrix Winkel γ um z-Achse: $M_z(\gamma) = \begin{pmatrix} \cos\gamma & -\sin\gamma & 0 \\ \sin\gamma & \cos\gamma & 0 \\ 0 & 0 & 1 \end{pmatrix}$

→ Einsetzen in F und Ableiten liefert:

$$\frac{\partial F(\gamma)}{\partial \gamma} = 2\sin\gamma \sum_i (x_{i1} y_{i1} + x_{i2} y_{i2}) + 2\cos\gamma \sum_i (x_{i1} y_{i2} - x_{i2} y_{i1})$$

$U = x^T y$

$\gamma_{min} = \arctan[(u_{21} - u_{12}) / (u_{11} - u_{22})]$

→ iteratives Annähern an optimale Rotation, sukzessive Rotation um x-, y- & z-Achse

$v_M = x^T y_M = v M^T$ (M mit Drehmatrix)

→ Optimierungszyklus ist unabhängig von u:

$\forall (a,\varphi) \in \{(x,\alpha),(y,\beta),(z,\gamma)\}$ — Drehe y, x, z

bestimme φ_{min}

$v = v M_a(\varphi_{min})^T$

→ Abbruch: Summe der Winkeländerung $< \delta$

Optimierung der Rotation (Kabsch)

→ Kabsch

→ Drehmatrix U sind orthonormal: $U^T U = E$

→ Anwendung Lagrange-Methode zur bedingten Minimierung:

$$G_{xy}(U, L)$$

→ Ableitung von G: $U(S+L) = R$

↳ $R^T R = (S+L)^T (S+L)$

→ Eigenvektoren: a_1, a_2, a_3, Eigenwerte: $\mu_1 \geq \mu_2 \geq \mu_3$ von RTR

↳ Drehmatrix:

$$U = R\,[S+L]^{-1} = R A \Lambda^{-1} A^T$$

↳ $\Lambda = (\sqrt{\mu_1}, \sqrt{\mu_2}, \sqrt{\mu_3})\, E$

$A = (a_1, a_2, a_3)$

→ ~~det U = 1~~