CTW

Arbeiten mit Pharmakophoren

Problem:

geg: eine Menge von Molekülen, die an ein Protein binden

ges: gemeinsamer Pharmakophor

In der Regel steht die Struktur des Proteins / Bindungsmodi der Moleküle nicht zur Verfügung

Screening-Workflow

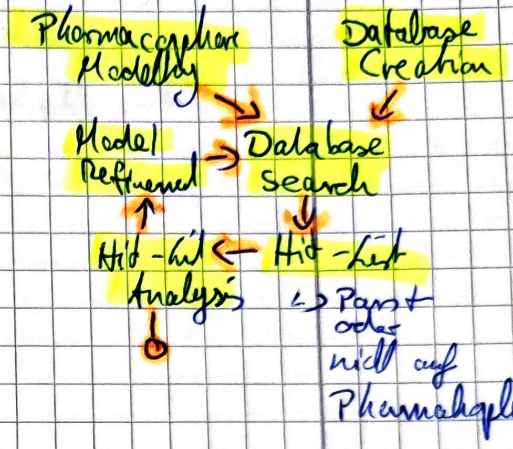

→ Ableiten eines initialen Pharmakophors

→ Pharmakophor-Matching

↳ Trefferlisten mit Molekül Konformation

→ Erhöhung der Sensitivität / Spezifität von Pharmakophoren durch Analyse von Hitlisten auf bekannten Aktiven / & Inaktiven

Algorithmen zur Ableitung von Pharmakophoren

→ Berechnung einer multiplen Überlagerung, Extraktion überlagerter

a) Gruppen

→ Active-Analog Approach:

↳ Identifikation von ‚essential groups': Gruppen die Pharmakophor bilden können

b) ↳ Suche nach dem Abstandsmuster:

↳ ∀ Moleküle: Generierung einer ‚orientation map'

↳ möglicher Pharmakophor ⇒ Punkt im kartesischen Raum

↳ Enumeration des Konformationsraums

↳ Schnitt der ‚orientation map' liefert den Raum möglicher Pharmakophore

↳ je mehr Moleküle, umso kleiner ist dieser Raum

CIW

Ableitung von Pharmakophoren

→ Active-Analog-Approach:

Orientation Maps:

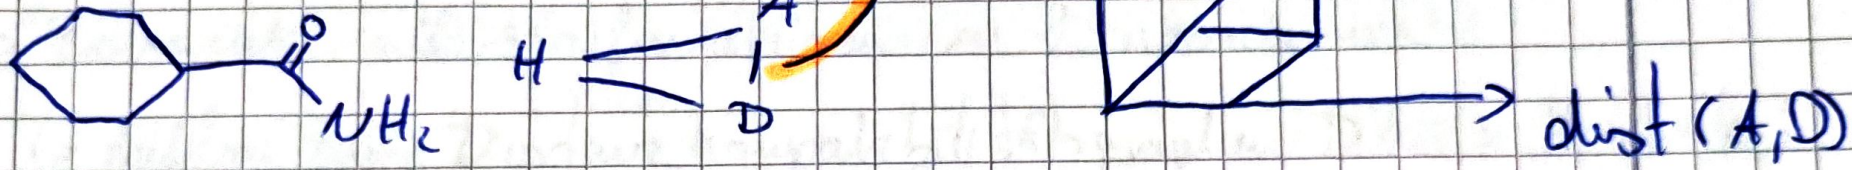

Jedes Molekül bildet eine Punktwolke durch mögliche Abstandsmuster des Pharmakophors durch

→ Variation der potenziellen Pharmakophorpunkte

→ Variation der Molekülkonformation

CIW

Ableitung von Pharmakophoren

→ DISCO

→ Identifikation von Pharmakophor-Punkte

→ Auswahl eines Referenzmoleküls R

→ Betrachte alle Konformationen von R nacheinander:

↳ Aufbau eines Distanzkompatibilitätsgraphen D für n Moleküle:

→ Knoten: Matchings von potentiellen Pharmakophor-Punkten (n+1 für Referenz, ein Eintrag aus jeder Struktur)

→ Kanten: falls die Matches distanzkompatibel (1 Å) sind

(Abstände in Referenz Mol ~ Gleich)

→ Bestimmung der Cliquen in D (Bron-Kerbosch): beschreiben mögliche Pharmakophore → // Stereoisomere überprüfen da nur Distanzen

→ iteratives Vorgehen, Stereoisomerie, Konformation der Moleküle
↳ erlöschen ↳ nicht!

<q c="0">

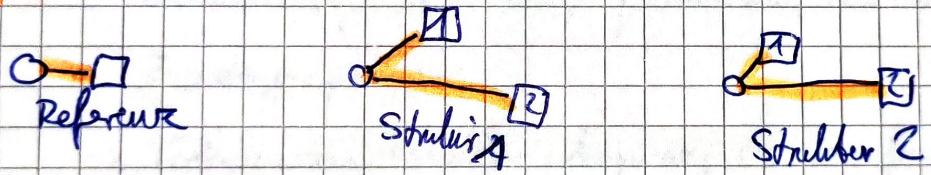

Distanzkompatibilitätsgraph

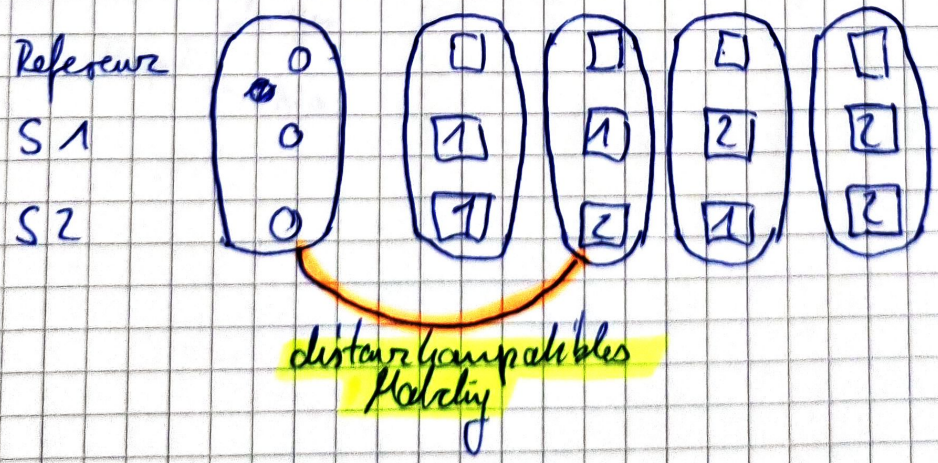

Algorithmen für Pharmakophor-Matching

Problem: 3D-DB Searching

gg: ein Pharmakophor P und eine Molekül-DB

ges: Moleküle, die P erfüllen und die Zuordnung von P zu den Molekülen

eg: CATALYST, CAVEAT, UNITY

CATALYST

→ Pharmakophor wird zum Filter verwendet, weitere Eigenschaften: Form Deskriptor, Text basierte Randbedingungen

→ Matching-Alg:

→ Hierarchischer Scan der Molekül- / Fragment-Konformere

→ Atom-für-Atom Matching:

→ Backtracking über aller paarweise distanzkompatiblen Zuordnungshypothesen

→ Toleranzen erlauben Anpassung der Konformation

All compounds
All fragments
All conf.
Map: ↪ yes
↪ No

Alle möglichen Konformationen

CIW

CAVEAT - Alg

Datenbank:
→ Speicherung von Vektorpaaren nach gem. Parametern: Distanz d, Torsionswinkel: t, 2 Öffnungswinkel: a_1, a_2
→ ∀ Moleküle: Definiere Auswahl von Vektoren (Bindungen, geeignete Ww, etc), ∀ Konformationen: Speichere alle Vektorpaare
→ Verwaltung: geometrisch charakterisierte Bins: uniform für d, a_1, a_2, Bin-Größe von t ist abhängig von a_2

Suchanfrage: Menge von Vektoren (Paarliste, Toleranzwerte)
Such-Algorithmus:
→ ∀ Vektorpaare der Anfrage: bestimme gültige Bins
→ durchlaufe Antwortlisten in Molekülreihenfolge: suche Moleküle, die alle Vektorpaare enthalten
→ ∀ gefundenen Moleküle: teste, ob die gesamte Anfrage (Konformation der Vektorpaare) erfüllt ist

→ Suche nach Linkerfragmenten (Vektor = Bindungen)
→ Suche nach Pharmakophoren (Vektor = Ww)

UNITY

Directed - Tweak Methode:

→ direkte Berücksichtigung des Konformationsraums

→ zuerst angewendet auf Protein Loop - Vorhersage

→ Variablen: Torsionswinkel einer Kette

→ Zielfunktion: Funktion über Atom - Atom - Distanzen, zB

→ Abweichung von vorgegebenen Zieldistanzen

→ vdW - Kontakte, Ringschluss - Bedingungen

Suchalgorithmus:

→ Enumeration der Zuordnung der PPPs eines Moleküls in zum Pharmakophor

→ Generierung von Konformationen unter Distanz - Randbed:

→ Atom - Atom - Abstand $d = f(\text{Torsionswinkel } \Theta, \ldots)$

→ $\partial d / \partial \Theta$

→ Numerische Optimierung minimiert Abweichung von Zielfunktion

→ Überprüfung, ob Pharmakophor innerhalb erlaubter Toleranzen erfüllt ist

CIW

Ligand Scout Alg

Charakterisierung von Pharmakophorpunkten:

→ Berechnung von Abstandshistogrammen pro Interaktionstyp

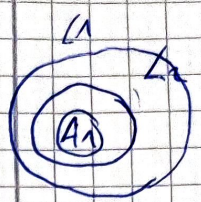

Matching-Alg:

→ Bilde alle Paare Ligand-Atom—Pharmakophorpunkt und bewerte den Fit

→ Suche das maximale, bipartite Matching

→ Transformation des Moleküls auf den Pharmakophor (Kabsch)

→ Entferne geometrisch nicht matchende Paare durch Anpassung der Fit-Werte

→ Wiederhole bis ein Matching mit geringen Abweichungen gefunden wurde

⇒ heuristisch

Pharmer-Alg

Indexbasiertes Verfahren zur Suche nach pharmakophor-matchenden Molekülen in DB

→ Aufbau eines räumlichen Index (KDB-Tree)

→ Einfügen aller Dreiecke zwischen Pharmakophorpunkten in Molekül (Typ, Dist)

→ Meta-Daten pro Dreieck: Lagen, Referenzen, karthesische Koord, Molekül, Bloomfilter

→ Sucheinfrage mit Pharmakophor:

→ Anfrage des KDB-trees mit allen Dreiecken des Pharmakophors

→ Sortierung der Trefferliste nach Molekülen

→ Berechnung der Überlagerung (Kabsch) mit einem radius-gewichteten RMSD

Quantitative Struktur-Wirkungsbeziehungen (QSAR)

Matched Molecular Pairs

Frage:
Wie wirkt sich eine Änderung der Molekülstruktur auf makroskopische Eigenschaften wie die Bioaktivität aus?

Matched Molecular Pair (MMP):
pair of molecules differing only by a particular (small) well-defined, structural transformation

Matched Molecular Pair Analysis (MMPA):
systematic method to identify MMPs from a set of compounds and to determine the associated property change

Matched Molecular Series (MMS):
a set of two or more molecules forming pairwise MMPs with identical scaffold

Vorteile:
(+) Vorhersage einer Eigenschaftsdifferenz ist einfacher als die Vorhersage des absoluten Wertes einer Eigenschaft
(+) Leicht interpretierbar, lernen aus Erfahrungen und Beispielen

CIW

Matched Molecular Pair Analysis

Ziel: Optimale Nutzung von Informationen in großen Molekül-Datensammlungen mit experimentellen Daten

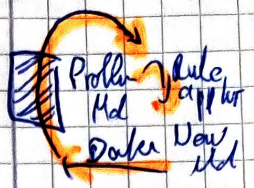

Vorgehen:

→ Suche eine Menge von Molekülpaaren (A, B), die sich nur die gleiche Transformation unterscheiden

→ Statistische Untersuchung der Änderung einer Eigenschaft ΔP über alle Molekülpaare (*, B)

↳ falls statistisch signifikant: Ableitung einer Regel $T \rightarrow \Delta P$, d.h. wird T auf Molekül X angewandt, erwarten wir die Eigenschaftsänderung ΔP für das resultierende Molekül

↳ Aufbau und Pflege einer Regelbasis

↑ Improvement ⊙ Consistent ↓ Detrimental

MMPA-Alg ! Transformations !

1) MMP-Identifikation über SMILES

→ User definiert eine Substruktur X als SMILES

→ Identifikation aller Moleküle, die X enthalten, für jedes Molekül A:

← → Generiere A − X durch Entfernen der Substruktur → Vergleich mit B

Nachteil: Substruktur X muss vorher definiert werden, nur bekannte Fragmente

2) MMP-Identifikation über SMARTS

→ User definiert eine mögliche Transformation T als SMARTS-Ausdruck

→ Anwendung von T auf Molekül A → Vergleich mit Molekül B

Vorteil: relativ effizient bei Einsatz von Substrukturen

Nachteil: Nur vorher von User definierte Transformationen identifiziert

MMPA-Alg

3) MMP bei MCS-Berechnung

→ Berechne den paarweisen MCS T zwischen allen Paaren (A,B)

→ Betrachte (A-T, B-T) und prüfe MMP-Eigenschaften:

→ jeweils ein zshgd Teilgraph, maximale Atomzahl

Vorteile: keine Vorabdefinition von Transformationen

Nachteil: sehr laufzeitintensiv

4) MMP bei Fragment-Indizierung (Hussain)

→ Schneide alle Moleküle an acyclischen Einfachbindungen

→ Prüfe Größe der Fragmente und baue einen Index

→ Identifiziere alle Paare (A,B) mit gleichem Schlüsselwert

→ Analoger Algorithmus für Doppelschnitte

Vorteile: keine Vorabdefinition von Transformationen, sehr schnell

1) Take input Molecule and enumerate all acyclic single cuts

A:

B: 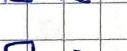

2) Index

Key

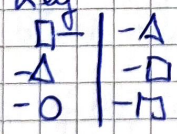

3) Mol A, Mol B

Double cuts:

Key	Value

Mol C, Mol D

Kritik: Vollwertige biologische Aktivitäten

MMPA: besser geeignet wenn gleiche Umgebung z.B. beobachtet in Wand

6-D) Matched Molecular Pairs (MMP)

1) QSAR:

An Hand von vielen Daten den Zusammenhang zw der chemischen Struktur und biologischer Wirkung zu ermitteln und zu beschreiben.

MMPA:

~~wie bekannt aus~~ auf einer Menge von Molekülpaaren (A,B), die sich nur durch die gleiche Transformation ∇ unterscheiden Analyse machen: Änderung einer Eigenschaft ΔP über alle Molekülpaare (A,B)

↳ wenn statistisch relevant Ableitung einer Regel ∇ → ΔP

Advantage MMPA:

→ leicht interpretierbar, lernen aus Erfahrungen

→ Vorhersage eines Eigenschaftsdifferenz einfacher als Vorhersage des absoluten Wertes Eigenschaft

2) Hussain and Rea

1) Take all input molecules and enumerate all acyclic cuts

2) Index those cuts saving (Key, Value) pairs, where Key is one side of the cut and Value are all possible other sides of the cut

3) Derive a transformation

CIW

(6-2)

4)

What is core?[2]

refers to the common structural component shared by HHPs;

What is context?[3]

refers to the surroundings around / variations around the core

→ Equal for both!

CIW

(6-1) QSAR

1) a)

$$X \times b = a$$

$$\begin{pmatrix} S_{11} & & & & S_{15} & S_{21} & & & S_{25} \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \times \begin{pmatrix} q_1 \\ \vdots \\ q_9 \end{pmatrix} = \begin{pmatrix} 7,46 \\ 8,16 \\ \vdots \end{pmatrix}$$

(X: y; a)

b) **Correlation Coefficient:**

a numerical value that indicates how closely two variables are related to each other [-1, 1]

0: no linear relation

0,5: moderate linear relation: one increase the other also

1: perfect linear relation.

-1: one increases the other decreases

c) Correlation coefficient 0,94 is high -> high fit to the learning data

d) Meaning of the coefficients of the independent variables?

↳ represent the quantitative contribution of each component for the activity

2) **Leave One out cross validation**

(Volume je ein Datenpunkt in die Testmenge, Rest in Trainingsmenge. Wiederholen

used to assess the performance and generalizability of a predictive model

CW

6-1)

3) What does the LOO q^2 tell us about a model?

$q^2 > 0$ = good

$q^2 = 0$ = not better than random

4) LOO q^2 and external q^2

LOO q^2: calculated during leave-one-out-cross validation

ext q^2: uses independent dataset that was not used during training

both high → model is good and reliable for new data

LOO q^2 high / q^2 low → overfitting data

both low → bad

CW

QSAR-Verfahren

QSAR (quantitative structure-activity relationships)

Erfassung und quantitative Beschreibung des Zusammenhangs zwischen chemischer Struktur und biologischer Wirkung

Input: Liste von Molekülen mit gemessener Aktivität

Ziele: → Vorhersage biologischer Aktivitäten von Molekülen
→ Ableitung von Modellen zur Erklärung biologischer Aktivität

Methode: → Beschreibung von Moleküleigenschaften
→ Suche nach Korrelationen mit gemessenen biologischen Aktivitäten

Physiko-Chemische Parameter

Beschreibung für die biologischen Aktivitäten relevanter Moleküleigenschaften:

→ Hammett-Konstante σ: Beschreibung elektronischer Eigenschaften, zB die Fähigkeiten, H-Brücken auszubilden

→ Lipophilieparameter π/log P: Beschreibung der Löslichkeit in hydrophober Umgebung

→ Molrefraktion MR: Polarisierbarkeit

→ Molekulargewicht MW: Größe des Moleküls

→ Verloop-Parameter: sterischer Parameter, beschreibt Länge und Breiten von Substituenten

CHW

Bestimmung der Lipophilie

-> Octanol als KM für lipophile Umgebung

-> P: Verteilungskoeffizient des Moleküls in Oktanol/Wasser

↳ log P: Maß für Lipophilie

-> Berechnung:

-> log P ist näherungsweise additiv über die Molekülgruppen

-> Lipophilbeitrag einer Gruppe X: $\pi(X) = \log P_{R-X} - \log P_{R-H}$

-> π: experimentell bestimmt

-> Vorgehen: Messung für Molekülgrundgerüst, Berechnung für alle Moleküle auf der Basis von π-Werten

QSAR

Hansch-Analyse

Ableitung eines Modells: → Aufhebung Linearität

$$\log 1/C = k_1 (\log P)^2 + k_2 \log P + k_3 \sigma + \ldots + k$$

↳ äquieffektive molare Dosen (Konzentration der Verbindung, die benötigt wird um einen gleichen biologischen Effekt zu erzielen)

$\log P, \sigma, \ldots$: Parameter zur Beschreibung der Moleküle

k_i: freie Parameter des Modells

Methode: lineare Regression

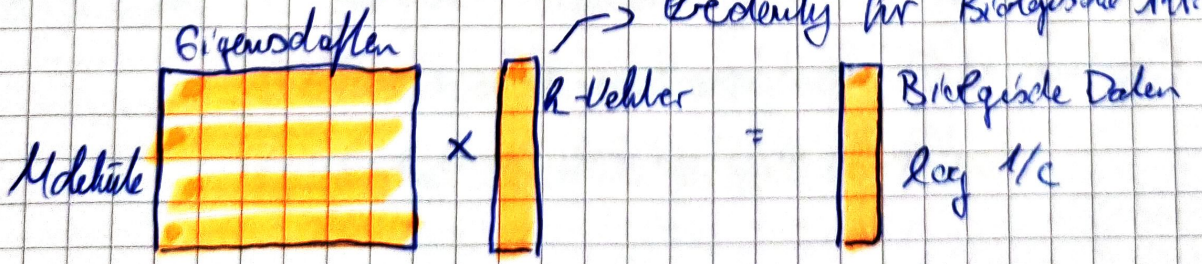

-> Berechnung für Biologische Aktivität

Bewertung: Größe der Abweichungsquadrate

CW

Free-Wilson-Analyse

Idee: Substituenten werden direkt mit der biologischen Aktivität korreliert:

→ Grundgerüst liefert Beitrag μ zur biologischen Aktivität

→ an einer Reihe von Substitutionsstellen $X_1, \ldots$ gibt es jeweils verschiedene Substituenten $s_{11}, \ldots, s_{1n}, s_{21}, \ldots, s_{2m}, \ldots$

→ durch Regression wird der Beitrag a_{ij} des Substituenten s_{ij} bestimmt:

Moleküle

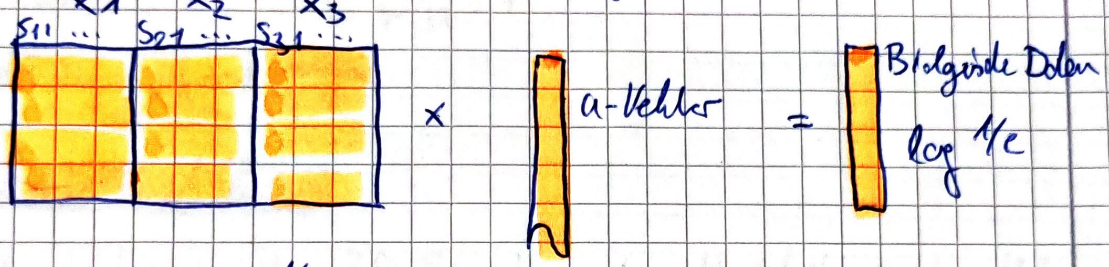

→ Modell $\log 1/c = \sum_{\text{Substitutionsstellen } i} \sum_{\text{Substituenten } j} a_{ij} \delta_{ij} + \mu$

→ $\delta_{ij} = 1$ falls Substituent s_{ij} an X_i steht

Nachteile: (-) mehrere Substitutionsstellen sind nötig

(-) große # freier Variablen → geringe Vorhersagekraft

(-) Vorhersage nur neue Kombination bekannter Substituenten

Vorteile: (+) einfache Durchführbarkeit (keine Kenntnis physikochem. Deskriptoren)

(+) Berücksichtigung Konstitution (wo Änderung)

(+) liefert quantitativ gute Modelle

Kaufmann'sche Ansatz

→ Berechnung physikochemischer Eigenschaften (k) für die Substituenten s_{ij}: ϕ_{ijk}

→ freie Parameter a_{ijk}: Eigenschaft k von Substituent s_{ij}

→ Modell

$$\lg 1/c = \sum_{\text{Substituentstellen } i} \sum_{\text{Substituent } j} \delta_{ij} \sum_{\text{Eigenschaft } k} a_{ijk} \phi_{ijk} + \mu$$

Free-Wilson: $k=1$, $\phi_{ijk}=1$

Hansch: $i=j=1$

3D-QSAR

→ Berücksichtigung der 3D-Struktur der Moleküle bei der Ableitung von QSAR-Modellen

→ Problem:

→ Konformationen und relative Orientierungen sind unbekannt

→ Beschreibung von gemeinsamen 3D-Eigenschaften

→ Methoden:

CoMFA: Vergleich von Molekülfeldern

CoMSIA: Vergleich von lokalen Molekülähnlichkeiten

CoMFA - Studien

→ Cramer

→ Voraussetzung: → Moleküle binden kompetitiv an das gleiche Zielprotein

→ Moleküle haben ein möglichst breites Spektrum an Affinitäten

→ Strukturelle Überlagerung ist bekannt oder berechnet

→ Methode:

→ Einbettung der überlagerten Moleküle in 3D-Gitter

→ Berechnung von Feldern an Gitterpunkten

→ Korrelation von Felddaten an Gitterpunkten mit biologischen Aktivitäten

→ Validierung des Models

→ Berechnung von CoMFA-Feldern: GRID

→ Berechnung der WW mit einer Probe, die auf den Gitterpunkt plaziert wird

→ sterisches Feld: Vdw-WW der Probe mit dem Molekül

→ elektrostatisches Feld: Coulomb-WW der Probe mit den Molekül

→ auch hydrophobes Feld

→ Problem: Potentiale (sterisch, elektrostatisch) sind nahe den Atomen unendlich groß: Verwendung von gekappten Funktionen (Gauß-Kurven)

→ Korrelation mit biologischen Daten

Datenmatrix: Zeilen: Moleküle, Spalten: Feldeinträge f_{xyz} für alle Feldtypen

freie Var: a_{xyz}: Relevanz des Eintrags f_{xyz} für biologische Wirkung

↳ ~~Biologische Wirkung ist Konstante~~ Erklärung Modell: Beitrag

Modell:

$$\log 1/C = \sum_{\text{Feld}} \sum_{\text{Gitter}\,x,y,z} a_{xyz} f_{xyz} + a$$

↳ Wenn a_{xyz} mit großer Varianz kann große Abweichung Größen

Problem: # freie Var >> # biologische Daten,

Verringerung der # freier Var: PCA, PLS

Variablenreduktionsverfahren

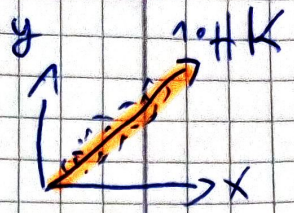

→ Bestimmung der Hauptkomponente

→ PCA (principle component analysis) Projektion auf Hyperebene

↳ Bestimmung orthogonaler Basis $z_1, \ldots$ in Richtung größter Varianz

↳ Ziel: Reduktion der Dimensionalität unter Beibehaltung der Varianz

→ Randbedingungen:

- $z_1, \ldots, z_s$ sind Linearkombination der Datenvektoren x_i
- $z_i, z_{i'}$ sind orthogonal $i \neq i'$
- Varianz σ_i^2 ist Maximal mit i und jeweils maximal

  oder minimiere $\|X - X' z\|$

→ Berechnung (D = Datenmatrix)

→ Kovarianz matrix $D^t D$ liefert die ersten k Vektoren

→ bestimme Eigenwerte / Eigenvektoren: $\lambda_i z_i$ mit $\lambda_0 > \lambda_1 > \ldots$

→ z_i sind die entsprechenden Basisvektoren

Nachteil: Basisvektoren werden ohne Berücksichtigung der gebundenen Daten (bzw.) bestimmt: korrelierende Daten werden ggf nicht gefunden

Partial-Least-Squares Verfahren

PLS (partial least squares):

- → lineare Regression (kleinste Quadrate) unter Berücksichtigung der H der Freiheitsgerade
- → Bestimmung einer orthogonalen Basis $z_1, \ldots$ (Projektionsgeraden) mit hoher Vorhersagekraft
- → Ziel: Reduktion der Dimensionalität unter Beibehaltung der Vorhersagekraft

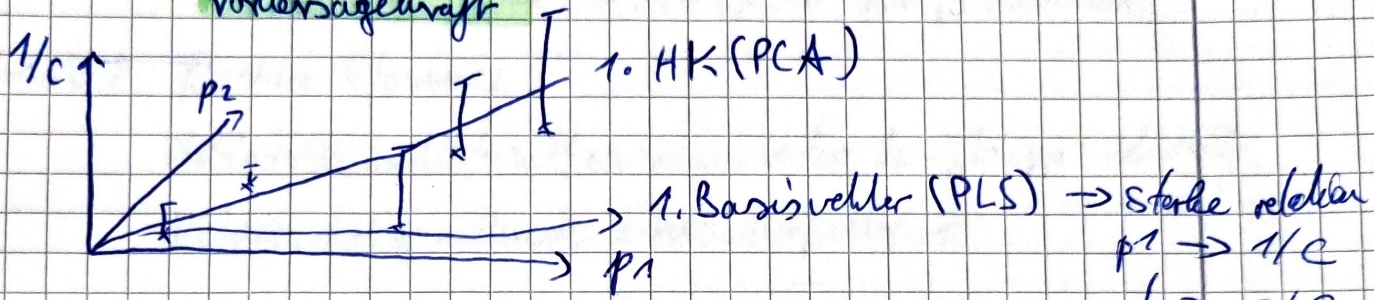

for (S=1, S<u, S++) // S ist Dimension des red. Modells

- → bestimme Basisvektor z_S mit hoher Korrelation der projizierten Datenmatrix mit ursprüng. Daten
- → füge z_S zum bisherigen Modell $(z_1, \ldots, z_{S-1})$ hinzu
- → berechne projizierte Datenmatrix X'
- → bestimme Abweichung: $X_r = X - \bar{z} X'$
- → berechne Vorhersagekraft des Modells mittels Kreuzvalidierung
  - ↳ für jede Datenzeile ol: berechne z_S ohne ol und sage ol voraus
  - ↳ quadr. Abweichung ist Maß für Vorhersagekraft * γ
- → Abbruch falls γ zu niedrig

CoMSIA

CoMFA Nachteile: Potentialfelder haben sehr steile Flanken, geometrisch schwer interpretierbar, numerisch instabil

CoMSIA: Moleküle werden direkt verglichen

2. CoMFA Methode:
→ an jedem Gitterpunkt wird die Ähnlichkeit der Moleküle mit der Probe bestimmt
→ Ähnlichkeitsindex: Überlapp von Gaußfunktionen

Vorteil: flachere Flanken,
definiertes endliches Maximum, daher kein Kappen notwendig
Felder sind geometrisch besser interpretierbar

Anwendung von 3D-QSAR Modellen

Vorhersage von Bindungsaffinitäten:
→ Überlagerung des unbekannten Moleküls mit den Molekülen des Modells
→ Berechnung der Felder für das unbekannte Molekül
→ Einsetzen der Felddaten in das Modell

Graphische Auswertung (Visualisierung des Modells):
→ jedem Gitterpunkt ist nach der Regression ein Signifikanzwert a_{xyz} zugeordnet
→ Für jedes Feld können Regionen mit hohen a_{xyz}-Werten visualisiert werden

Bewertung QSAR-Modelle

„Gutes Modell" : korrekte Vorhersage für unbekannte Moleküle

→ Aufteilung: Daten in Test- / Trainingsmenge
  Überprüfung Qualität ↵ ↳ Ableitung des Modells

→ „Leave n out cross validation":
  ↳ nehme jeweils n Datenpunkte in die Testmenge, den Rest in die Trainingsmenge
  ↳ Wiederhole Modellgenerierung / Test für alle Mengen von n Datenpunkten

→ Trennung einer Testmenge vor Ableitung des Modells
  ↳ Clustering der Moleküle nach Ähnlichkeit
    → Nach Diversität: entnehme einige Repräsentanten jedes Clusters
    → Nach Klassen: entnehme ganze Klassen (Cluster)

→ $y_1, \dots, y_n$: gemessene Werte, $\bar{y}$: Mittelwert

→ $p_1, \dots, p_n$: mit dem Modell vorhergesagte Werte, $\bar{p}$: Mittelwert

→ Wie gut approximiert das Modell die Trainingsmenge?

$RSS = SSE = \sum_i^n (y_i - p_i)^2$ // Residual Sum of squares = Sum of squared Errors

$MSE = \frac{1}{n} \sum_i^n (y_i - p_i)^2$ // Mean square error

$RMSE = \sqrt{\frac{1}{n} \sum_i^n (y_i - p_i)^2}$ // ROOT MSE

↳ Wertebereich: $0 - \infty$, 0 = identisch

→ Ein niedriger RSS-Wert zeigt, dass die Daten durch das QSAR-Modell beschrieben werden können.

↳ NICHT: dass unbekannte Moleküle mit hoher Genauigkeit vorhergesagt kann

CIW

Bewertung QSAR

→ (Pearson-) Korrelationskoeffizient (r-Wert), auch Bestimmtheitsmaß (r^2)

$$r = \frac{\sum_i^n (p_i - \bar{p})(y_i - \bar{y})}{\sqrt{\sum_i^n (p_i - \bar{p})^2} \sqrt{\sum_i^n (y_i - \bar{y})^2}}$$

↳ antikorreliert

$r \in [-1, 1]$

↳ korreliert

$r \in [0, 1]$

↳ korreliert

→ R^2-Wert (normale, quadratische Fehler):

$$R^2 = 1 - \frac{\sum_i^n (p_i - y_i)^2}{\sum_i^n (y_i - \bar{y})^2} \qquad \in [-\infty, +1]$$

↳ identisch

↳ auch residuale Fehler berücksichtigt

Wie gut approximiert das Modell die Testmenge?

→ Funktionen für r^2, R^2 können auch auf die Testmenge, bzw. in der Kreuzvalidierung angewendet werden → q^2, Q^2

PROBLEME:

→ sind sehr ähnliche Moleküle in Test/Trainingsmenge, dann ist q^2, Q^2 sehr ähnlich wie r^2, R^2 (nicht unbekannte Moleküle)

→ Zur Berechnung des q^2-Wertes mit Kreuzvalidierung wird mit ein Modell, daraus sehr viele Modelle hervorgehen

Docking

Docking: geg: 3D-Struktur des Zielproteins P,
(3D) Struktur eines zweiten Moleküls L
ges: Bindet L an P, falls ja mit welcher Bindungsaffinität?
Wie sieht die Struktur des P-L Komplexes aus?

Taxonomie:

Beteiligte Moleküle: → Macromolecular Docking eg: Protein-Protein
→ Small-Molecule Docking eg: Protein-Peptid

Berücksichtigung der Flexibilität: → starr/rigid-body: beide Moleküle starr
→ (semi-) flexibel: ein Molekül starr, das andere flexibel
→ flexibel: beide Moleküle flexibel

Modellierung der Flexibilität: → kontinuierlich
→ diskret: durch eine feste Menge von Alternativen pro Freiheitsgrad
→ Ensemble: feste Menge von Konformationen

Bewertungsfunktionen

geg: 3D-Struktur eines Protein-Ligand Komplexes
ges: freie Bindungsenergie ΔG (freie Enthalpie) $\Delta G = -RT \ln K_i$
→ gemessene ΔG beschreibt die Energiedifferenz zw. gebundenem und ungebundenem Zustand; bezieht sich auf Ensemble von Komplex-Strukturen dominiert
→ Annahme: gemessene ΔG wird durch eine Struktur mit minimaler Energie
→ $\Delta G = \Delta H - T\Delta S$, ΔH: enthalpische Energie, ΔS: entropische Energie
→ Gleichgewichtsdissoziationskonstante $K_i = [P][L] / [PL]$

Bewertungsfunktionen

→ **Kraftfeld:**
- → beschreibt nur Enthalpie ΔH, liefert keine Aussage für ΔG
- → Konformationsterme (Bindungslänge / -winkel) haben sehr steile Flanken, ggf. nicht berücksichtigen
- → ggf. aufwendige Berechnung

→ **Potential of Mean Force:**
- → Analyse existierender Komplexe: "was häufig vorkommt ist energetisch günstig"
- → Paarpotentiale: $f(a,b,d)$ = relative Häufigkeit, mit der Atome vom Typ a und b mit Abstand d in Komplex-DB vorkommen
  - ↳ Umwandlung in Energiebeitrag $g_{ab}(d)$ (inverses Boltzmann)

  Gesamtenergie: $E(R,L) = \sum_{\text{Atome } r_i \in R,L} g_{a(r)a(l)}(d(r,l))$

→ **Empirische Scoring-Funktion:**
- → Kalibrierung mikroskopischer Eigenschaften mit gemessenen makroskopischen (ΔG werden) (geometrisches) ↳ QSAR
- → Datenbasis: Menge von PL-Komplexen mit bekannter 3D-Struktur & ΔG

eg: **Böhm-Funktion:**

Scoring-Funktion: $\Delta G = \Delta G_0 + \Delta G_{rot} N_{rot} + \Delta G_{H/b} \sum_{\text{neutral H-bonds}} f(\Delta R) f(\Delta\alpha) + \Delta G_{i/o} \sum_{\text{ionic}} f(\Delta R) f(\Delta\alpha) + \Delta G_{lipo} |A_{lipo}|$

ΔG_0: Verlust an Translations- / Rotationsentropie durch Bindg

ΔG_{rot}: Verlust an Konformationsfreiheitsgraden

$\Delta G_{H/b}$ / $\Delta G_{i/o}$: Wasserstoffbrücken (neutral / geladen)

ΔG_{lipo}: lipophile Kontaktfläche

Funktion f bestraft Abweichung der H-Brücken von der Idealgeometrie

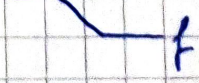

ΔG-Werte durch lineare Regression bestimmen

Rigid-body Protein-Ligand Docking

Rigides-Starres Docking

Cliquensuche – basische Verfahren

Docking:

→ Idee: Ligand-Orientierung nach sterischem Fit
↳ Form

→ Protein-Repräsentation:

→ Einbeschreibung von Kugeln in das aktive Zentrum:

→ Connolly-Oberfläche P wird durch Punkte / Oberflächenmannigfaltigkeiten approximiert

schwach zufällige Oberfläche

→ ∀ Punkt (p, n) wird eine Kugel k(p, n) generiert mit:

↳ p liegt auf der Oberfläche von k(p, n)

↳ der Mittelpunkt von k(p, n) liegt auf der Geraden p + λn

↳ k(p, n) hat maximalen Radius ohne Punkte aus P einzuschließen

→ Kugeln werden gefiltert (geometrisch (Winkel zw. Berührpunkten)) und gedünnt

→ Berechnung von Molekülen zu Kugeln und Ligand-Atomen:

→ zwei Moleküle $(l_1, h_1), (l_2, h_2)$ sind distanz-kompatibel g.d.w.

$$|d(l_1, l_2) - d(h_1, h_2)| < \varepsilon$$

→ Suche nach Molekülen $M = \{(l_i, h_i)\}$ mit $\max_{i,j} \{|d(l_i, l_j) - d(h_i, h_j)|\} < \varepsilon$

→ Alg:

→ rekursive Enumeration aller Moleküle M mit $|M| = 4$

→ Orientierung des Moleküls durch eine RMSD-Fit Routine

→ Filtern der Orientierungen: Überlapp, Sterische Clashes, etc.

→ Erweitern des Moleküls

→ Optimierung der Orientierung (Fitting aller Ligand-Atome auf nächste Kugeln)

→ Energetische Bewertung → ΔG

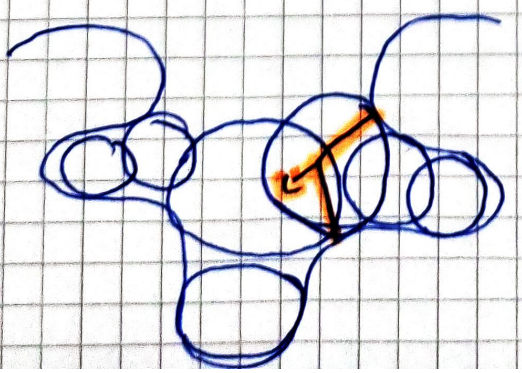

Kabsch-Alg

Docking-Problem: geg. Site-Punkte S, Molekülpunkte M,
suche Transformation (Ω, t) die $|C|$ maximiert:

$$C = \{(s,m) \in S \times M \mid s = \Omega m + t\}$$

Docking-Graph:

Knoten: Paaren $S \times M$, Kanten: distanzkompatible Paaren

Cliquen beschreiben distanzkompatible Mehrlinge

Cliquensuche mit Bron-Kerbosch-Alg:

Ausschluss energetisch ungünstiger Paaren durch „pivot"-Menge (vorher auswählen)

Laufzeiteffizienz:

→ Cliquensuche ist NP-schwer, BK-Alg exponentiell, typisch gilt dies nicht für das Docking-Problem

CLIX-Alg

Berechnung einer Vdw-Karte im diskreten Zustand (GRID) und Vdw-Gruppen in Liganden

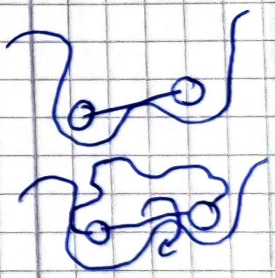

Alg:
- Identifikation von Vdw-Targets in der Vdw-Karte (Radiale, energetische Minima für verschiedene Proben)
- Enumeration aller Paare von distanzkompatiblen Paaren zu Targets und Gruppen
- Überlagerung der Gruppen/Targets, Optimierung der Rotation um gemeinsame Achse durch Drehen in diskreten Schritten:
  - ↳ Suche nach zusätzlichem Paar
  - ↳ Überlappfrei, energetische Bewertung
  - ↳ Platzierung auf 2 Punkte
  - ↳ Drehe
  - ↳ Bewerte

Geometric-Hashing basierte Verfahren

Rigides Docking

Fischer:
- → Direkte Suche in einer Ligand-DB
- → Methode aus der Mustererkennung
- → Verwendet Kugel-Repräsentation von DOCK

Aufbau einer Hashtabelle: ∀ Ligand-Atomtripletts (a,b,c):

Eintrag mit Adresse [d(a,b), d(a,c), d(b,c)]: (Ligand, basis)

(basis ist das Atompaar (a,b))

↳ zwei Atome des Liganden gematcht auf zwei Kugel des Pockets

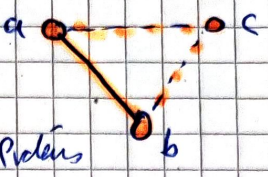

Suchalgorithmus:

1: seed-matching: Suche nach Matching von Basen mit vielen Matches von Drittatomen C

2: extension of matching: Überprüfung und Erweiterung der Matchings aus 1.

→ Suche nach Seed-Matchings: (Voting-Scheme)

∀ Kugelpaare (a,b):

∀ Kugeln C:

∀ (ligand, basis) aus Hashtabelle [d(a,b), d(a,c), d(b,c)]:

→ Erhöhe das Voting für (ligand, basis)

→ Füge (3-tes Ligand-Atom, c) in die Matchingliste (basis, Ligandatom)

∀ (ligand, basis) mit Voting > ∇:

→ Überprüfe alle paarweisen Distanzen

→ Aufnahme in Seed-Matching Liste

→ Erweiterung eines Matchings:

→ RMSD-Fit der Ligand-Atome auf Kugeln gemäß Matching

→ Anpassung des Matchings, Überlappfaktor, Bewertung

→ Unterschiede zur Mustererkennung

→ Muster-Ordnung: d-dim. Basis definiert eindeutiges Referenz-Koordinatensystem

→ Aufgrund der Komplexität nur 2-dim. Basis

⇒ Matches mit ggf nicht zu überlagern