GrCl

Ähnlichkeitsprinzip

Molekulare Erkennung:
- Bindung eines Moleküls an ein Protein P
- basiert auf spezifische Anordnung funktioneller Gruppen in Raum
- Moleküle die an P binden, sind ähnlich zueinander

Molekulare Ähnlichkeit:
- Ziel: Moleküle sind ähnlich bzgl. Protein P, wenn sie sich bei der Bindung an P gleich verhalten
- Problem: P ist unbekannt

Protein-Ligand-Komplexe

- intermolekulare Wechselwirkung: fundamentale Eigenschaft, auf die alle Lebensprozesse basieren
- Komplexbildung: spezifische Anlagerung eines Moleküls an ein anderes
- Charakteristika:
  - Bindung basiert auf schwachen, kurzen Wechselwirkungen
  - Sind Ligand flexibel
  - Abschätzung Energie ist schwer
- Bindungskonstante: $K_i = \frac{[\text{Ligand}][\text{Protein}]}{[\text{Ligand} \cdot \text{Protein}]}$
  - Anteil des Liganden der im Mittel an das Protein gebunden ist
  - je kleiner desto stärker
- freie Bindungsenthalpie $\Delta G = RT \ln K_i$
- IC_{50}: Ligandkonzentration, bei der die Proteinaktivität um 50% absinkt

BRUNNEN

QCI

Typen von Protein-Ligand-Wechsel

- Kovalente Bindung
- Wasserstoffbrücken
- Ionische WW
- Metall Komplexierung
- Hydrophober Effekt
- Entropische Beiträge

Ähnlichkeitsprinzip

Moleküle mit ähnlichen physiko-chemischen Eigenschaften verhalten sich statistisch auch bei der Bindung an Proteine ähnlich!

↳ Designgrundsatz falls Protein unbekannt ist.

↳ nur „statistisch"!

→ Die für die Bindung relevanten funktionellen Gruppen sind nicht bekannt

→ Kleine Änderungen in der Struktur können Affinität herabsetzen

→ Moleküle binden nur partiell an die gleiche Stelle im aktiven Zentrum

Anwendung molekularer Ähnlichkeit

Start bei: Eines/Mehrere Moleküle mit bekannten Bindungseigenschaften an Zielprotein P

Ziel: → Such nach weiteren Molekülen in DB

→ Bestimmung der relevanten funkt. Gruppen

→ Vorhersage Bindungseigenschaft

- Optimierung von Moleküleigenschaften unter Beibehaltung der Bindungseigenschaft
- Auswahl einer Menge zum Screening

BRUNNEN

GrCl

Molekulare Descriptoren

Ziel: Beschreibung von Molekülen für die effiziente, computergestützte, quantitative Charakterisierung von molekularer Ähnlichkeit.

Properties:

I) Welche Art von „Ähnlichkeit"?

II) pharmakologisch: ähnlich, wenn sie sich in biologischen Systemen ähnlich verhalten

IV) chemisch: ähnlich, wenn sie aus ähnlichen funkt. Gruppen aufgebaut sind

III) Welche Eigenschaften?

I) Makroskopisch, physikalische Prop's

II) Topologische Indizes

III) Molekülstruktur

IV) Räumliche Konfiguration des Moleküls

III) Welche Struktur hat der resultierende Deskriptor?

Skalar, Vektor, Funktion, Graph, Feld

↳ Struktur entscheidet über:

I) Platzbedarf

II) Algorithmik-um Vergleich

BRUNNEN

GrCI

Topologische Indizes

- **Wiener-Index:**
  - → All-Pairs shortest Path
  - → Summe der kürzesten Pfade zwischen allen Nicht-H-Atomen im Molekül

$$W = \sum_{\text{Atompaare } i,j} d(a_i, a_j)$$

  - → Mit Floyd-Warshall-Alg in $O(n^3)$
  - → modelliert „Kompaktheit" eines Moleküls
  - → nicht normalisiert
  - → Max für keine Verzweigung: $W(N) = \frac{1}{6}(N-1)N(N+1)$

- **Floyd-Warshall-Alg**

In: (gewichtete) Adjazenzmatrix des Mol-Graphen

$$W = (w_{ij})_{1 \le i,j \le n} \text{ mit } w_{ij} = \begin{cases} 0 & : i = j \\ 1 & : \text{Atome } i \text{ \& } j \text{ sind kovalent gebunden} \\ \infty & : \text{else} \end{cases}$$

Out: Matrix mit allen paarweisen kürzesten Pfadlängen

→ Zwischenknoten: Auf einem Pfad $p = (v_0 = i, v_1, \dots, v_{m-1} = j)$ werden die Knoten $v_1, \dots, v_{m-2}$ als Zwischenknoten bezeichnet

→ Idee: kürzester Pfad der nur Zwischenknoten $\{1, \dots, k\}$ verwendet kann über kürzesten Pfade, der nur Zwischenknoten $\{1, k-1\}$ verwendet, berechnet werden

BRUNNEN

GCI

Wieso - Index / Floyd Warshall

Rekursion: $d_{ij}(k)$: Länge kürzeste Pfad von i nach j, auf dessen Pfad neben i & j nur Knoten aus $\{1, .. k\}$ besucht werden

$$d_{ij}^{(k)} = \begin{cases} w_{ij} & : k = 0 \\ \min\{d_{ij}^{(k-1)}, d_{ik}^{(k-1)} + d_{kj}^{(k-1)}\} & : k > 0 \end{cases}$$

```
FLOYD-WARSHALL (W)
    n = W.rows
    D^0 = W
    for (k = 1 to n)
      for (i = 1 to n)
        for (j = 1 to n)
          d_ij^k = min(d_ij^(k-1), d_ik^(k-1) + d_kj^(k-1))
    return D^n
```

Space $\Theta(n^2)$

Time $\Theta(n^3)$

BRUNNEN

GCI

Topologische Deskriptoren

- Randić-Index:

  Ziel: Beschreibung des Grades an „Verzweigung" (Verzweigtheit) eines Moleküls

  Wie bei Kanonisierung: Min Adjazenzmatrix

  - Moleküle mit gleicher # Atomen können mit Randić-Index verglichen werden
    - ↳ Aufwendige Berechnung

$$\Rightarrow \text{Randić Index: } R = \sum_{\text{Bonds}(a_i, a_j)} \frac{1}{\sqrt{\deg_{\text{no-H}}(a_i)\,\deg_{\text{no-H}}(a_j)}}$$

→ Für Isomere bis Oktan erfüllt RI das was GK aussagt

GCI

Structural-Keys

Fingerprints: $\{0,1\}$-Vektoren

Count Fingerprints: $\mathbb{N}$-Vektoren

→ durch eine Liste von Ja/Nein-Fragen erzeugt:

I (Fingerprint): jede Frage ein Bit im Vektor

II (Hashed Fingerprint): Hash-Funktion

Ist eine Eigenschaft vorhanden → Menge von Bits, die auf 1 gesetzt werden.

(+): Fingerprint Länge unabhängig von der # an Eigenschaften

(−): Bit-Positionen können nicht auf die Struktur rückgeschlossen werden.

→ Beschreibung der auftretenden „Bausteine" im Molekül

→ Def Liste von Gruppen:

Atome, Ringe, funkt. Gruppen, etc.

→ Molekül M → Bitvektor B:

$b_i = 1 \iff$ Gruppe i ist Subgraph von M (matcht)

→ Nutzung zur effizienten Substruktursuche (Filter):

$B_P(i) \wedge \neg B_M(i) \Rightarrow P$ ist nicht subgraph von M

→ kurzer Fingerprint: effizienter Vergleich, wenig Speicherbedarf

→ langer Fingerprint: enthält viele Gruppen, sehr selektiv

→ Problem: → Auswahl der geeigneten Liste

→ Länge der Liste = Länge Fingerprint

BRUNNEN

GCI

Hashed Fingerprint

-> Statt vorgegebener Liste: verwende generische, automatische Erzeugung Menge von Gruppen.

-> Statt vorgegebener Nummer: generiere eine ID auf der Basis der Gruppenbeschreibung

-> eg: Daylight Fingerprints

-> eg:

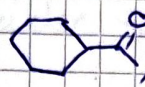

1 O, NH_2, C
2 O-C, NH_2-C, C-C
3 O-C-NH_2, O-C-C, C-C-C, N_{H_2}-CC

Von der Gruppe (Pfad) zum Bitmuster:

I) Gruppe muss zunächst in eine kanonische Form überführt werden

eg: pfade: Richtig mit kleiner lex Ordnung
zirkulär: Ordne nach Abstand

II) Kanonische Form wird einem Bit zugeordnet

01: Fingerprint, fixed

02: speicherer IDs der 1-Bits

03: Hashfunktion, (+) Käye frei, (-) Kollisionen

eg: Bloom-Filter

probabilistische Datenstruktur für den Test, ob ein Element in einer Menge vorkommt

BRUNNEN

GrCl

Hashed - Fingerprints

Pfade → Kanonisierung → ASCII-String → Integer → Zufallsgenerator → OR-Verknüpfung

Daylight - Methode

-> Hashing: Projektionen in eine Anzahl feste Länge
-> Pfad dient als „seed" eines Zufallsgenerators
4-8 Bits werden mit Fingerprint OR-verknüpft
-> Problem: nicht umkehrbar
-> Filter bei der Substruktursuche da deterministisch

Allgemeine Fingerprints

-> Problem der 1-Dichte:
-> Ähnlichkeit zw zwei kleinen Mol ist geringer als zw zwei großen Mol
-> Trade-Off Speicherverbrauch & Screening-Performance

-> Problem der Häufigkeiten:
-> Mehrfaches auftreten einer Gruppe nicht dargestellt
=> Holograme; stellt auftreten Häufigkeit

BRUNNEN

GCI

Extended Connectivity Fingerprints (ECFP)

-> Basiert auf Morgan-Alg

-> Beschreibung der Moleküle durch die Menge von „Features"

↳ Features werden auf $-2^{31} - 2^{31}-1$ abgebildet

Alg ECFP

Phase 1: Initial Assignment Stage (Zuordnung initialer Atom-Identifier)

Phase 2a: Iterative Updating Stage (Verknüpfung der Atom-Identifier mit denen der kovalent gebundenen Nachbarn)

Phase 2b: Duplicate Identifier Removal Stage (Entfernung von Duplikaten)

- **Phase 1: Initial Assignment Stage**

-> ECFP: detaillierte Beschreibung der atomaren Struktur

- f_{ECFP} (Knotengrad, # nicht-H Bind., Element, Gewicht, sp (Ladg), als (Ladg), Valenz, Zyklisch-Flag) = ⟨initial ID⟩

-> FCFP: Beschreibung pharmakophorer Eigenschaften

-> Feature Vektor: - Speichert alle im Verlauf erzeugten Features

↳ Feature-Identifier ist Menge von Bindg, die das Feature beschreibt

Alg ECFP

- **Phase 2a: Iterative Updating Stage**
  - → Einbeziehung der Nachbaratomen

```
iterative_update ( atom a, bondset bset[I])
    V[0] = iteration_no; V[1] = atom_id[a]; length = 2;
    B[a] = adjacency list of a, sorted by bond order (s>d>t>a)
           and atom_id[.] of second incident atom
    new_bset[a] = bset[a]
    for (∀ b in B[a]) do
        V[length++] = bond_order[b]; V[length++] = atom_id[b.incident_atom]
        if (is_stereo[a] & stereo chemistry is fully defined in this iteration) then
            V[length++] = stereo_flag[a];
        new_bset[a] = new_bset[a] ∪ bset[b.incident_atom] ∪ {b}
    new_atom_id[a] = hash_function(V, length)

iterative_update_stage ( Atom A)
    for ∀ a ∈ A do iterative_update ( a, bset);
    for ∀ a ∈ A do atom_id[a] = new_atom_id[a]; bset[a] = new_bset[a]
    for ∀ a ∈ A do attach (atom_id[a], bset[a]) to feature_vector
                   (only attach if it is duplicate 2b)
```

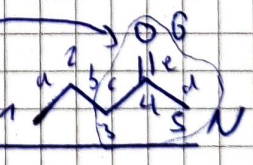

It	Atoms (same vector)					
	1	2	3	4	5	6
0	h1	h2	h2	h3	h4	h5
1	h6	h7	h8	h9	h10	h11

h9 = hash([1,3], [1,2], [1,4], [2,5]), (0 0 1 1))

Hash from Neighbors & itself

Bondset

GCI

Alg ECPP

- Phase 2b: Duplicate Removal
  - -> Verschiedene Strukturen können irgendwann bei gleichen Subgraphen
  - -> Da Strukturen anders als andere Hashing.
  - -> Speichere jede Substruktur im Feature Vektor nur einmal
    - ↳ Substruktur ≙ Bandset
    - ↳ Substruktur mit kleinster Iterationszahl überlebt
    - ↳ In einer Iteration kleinste Hashwert
    - ↳ Einmal Double einer Double 😊

-> Anzahl Iterationen: je nach Anwendung

-> Anwendung: Screening, Struktur-Aktivitätsmodellierung, Library Design

GCI

Ähnlichkeits-/Distanzmaße

Ziel: Bestimmung eines numerischen Wertes zur Quantifizierung der Ähnlichkeit zwischen zwei Objekten.

→ Objekte werden durch n-dimensionalen Feature-Vektor beschrieben
↳ i-the Eintrag → i-the Eigenschaft

→ Repräsentation durch Mengensysteme

$F = \{f_1, .., f_n\}$ alle Features

Merkmal A: $F_A = \{f_i \in F \mid x_i = 1\}$; $x_A = (x_1, .., x_n)$

→ Wertebereiche:

- Ähnlichkeit (normiert): $[0,1]$
- Distanz: $[0, \infty)$

→ $d(x,y) = 1 - a(x,y)$

→ $a(x,y) = 1 / 1 + d(x,y)$

→ Monotonie:

Zwei Ähnlichkeitsmaße a, b heißen monoton, iff $\forall$ Menge der gleiche Rangfolge implizieren: $\forall x,y,z: a(x,y) \leq a(x,z) \Leftrightarrow b(x,y) \leq b(x,z)$

→ Metrik:

1) $\forall a,b \in R: d(a,b) \geq 0$
2) $\forall a \in R: d(a,a) = 0$
3) $\forall a,b \in R: a \neq b \Rightarrow d(a,b) > 0$
4) $\forall a,b \in R: d(a,b) = d(b,a)$
5) $\forall a,b,c \in R: d(a,b) \leq d(a,c) + d(c,b)$

Semimetrik: 1-4

Pseudometrik: 1, 2, 4, 5

GdCI

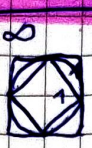

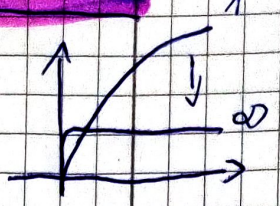

p-Normen

→ Metrik

→ $\|X\|_p = \sqrt[p]{\left(\sum_{i=1}^{n} |x_i|^p\right)}$; $d_p(a,b) = \|a-b\|_p = \sqrt[p]{\left(\sum_{i=1}^{n} |a_i - b_i|^p\right)}$

→ Binäre Vektoren x_A, x_B:

a = # 1-Bits in x_A, $a = \sum_{i=1}^{n} a_i$

b = # 1-Bits in x_B, $b = \sum_{i=1}^{n} b_i$

c = # 1-Bits gemeinsam in x_A & x_B, $c = \sum_{i=1}^{n} a_i \cdot b_i$

d = # 0-Bits gemeinsam in x_A & x_B, $d = \sum_{i=1}^{n} (1-a_i)(1-b_i)$

α = Menge 1 Bits in x_A, $\alpha = \{ i \in \{1,\dots,n\} \mid a_i = 1 \}$

β = Menge 1 Bits in x_B, $\beta = \{ i \in \{1,\dots,n\} \mid b_i = 1 \}$

Manhatten Distanz

$x_a, x_b \in \mathbb{R}^n$: $d_1(x_a, x_b) = \sum_{i=1}^{n} |a_i - b_i|$

→ normiert $\{1,0\}^n$ mit $1/n$, Wertebereich: $\mathbb{R}^n$: $0 - \infty$

→ $\{0,1\}^n$: $0 - n$ $d_1(x_a, x_b) = a + b - 2c$

Euklidische Distanz p=2

$x_a, x_b \in \mathbb{R}^n$, $d_2(x_a, x_b) = \sqrt{\sum_{i=1}^{n} |a_i - b_i|^2}$

Wertebereich: $\mathbb{R}^n$: $0 - \infty$

$\{0,1\}^n$: $0 - \sqrt{n}$; Norm mit $1/\sqrt{n}$ $d_2(x_a, x_b) = \sqrt{a + b - 2c}$

→ Manchai zur 1-Norm

GCI

Soergel-Distanz: Normierte Hamy Distanz

$X_a, X_b \in \mathbb{R}^n$: $d_s(X_a, X_b) = \frac{\sum_{i=1}^{n} |a_i - b_i|}{\sum_{i=1}^{n} \max(a_i, b_i)}$

Wertebereich: $\mathbb{R}^n$: $0 - \infty$, normalisiert $a_i \geq 0$ & $b_i \geq 0 \Rightarrow$ metrisch

$\{0,1\}^n$: $0 - 1$, $d_s(X_a, X_b) = \frac{a+b-2c}{a+b-c}$

Tanimoto-Koeffizient: Gemeinsame Eigenschaften

$X_a, X_b \in \mathbb{R}^n$: $s_t(X_a, X_b) = \frac{\sum_{i=1}^{n} a_i b_i}{\sum_{i=1}^{n} a_i^2 + \sum_{i=1}^{n} b_i^2 - \sum_{i=1}^{n} a_i b_i}$

Jaccard $\frac{|U \cap V|}{|U \cup V|}$

Wertebereich: $\mathbb{R}^n$: $-0{,}33 - 1$

$\{0,1\}^n$: $0 - 1$, $s_t(X_a, X_b) = \frac{c}{a+b-c}$

Soergel-Distanz: $s_t(X_a, X_b) = 1 - d_s(X_a, X_b)$

monoton zu Dice, korreliert mit Cosinus

Dice-Koeffizient

$X_a, X_b \in \mathbb{R}^n$: $s_d(X_a, X_b) = \frac{2 \sum_{i=1}^{n} a_i b_i}{\sum_{i=1}^{n} a_i^2 + \sum_{i=1}^{n} b_i^2}$

Wertebereich: $\mathbb{R}^n$: $-1 - 1$

$\{0,1\}^n$: $0 - 1$, $s_d(X_a, X_b) = \frac{2c}{a+b}$

monoton zu Tanimoto

GCI

Kosinus-Koeffizient

$X_a, X_b \in \mathbb{R}^n$:

$$s_K(X_a, X_b) = \frac{\sum_{i=1}^{n} a_i b_i}{\sqrt{\left(\sum_{i=1}^{n} a_i^2\right)\left(\sum_{i=1}^{n} b_i^2\right)}}$$

Wertebereich: $\mathbb{R}^n$: $-1 \dots +1$

$\{0,1\}^n$: $0 \dots 1$, $s_K(X_a, X_b) = \frac{c}{\sqrt{ab}}$

Tversky-Koeffizient

$X_a, X_b \in \{0,1\}^n$:

$$s_{u,v}(X_a, X_b) = \frac{c}{u(a-c) + v(b-c) + c}$$

$u \neq v$: asymetrisch

$u = 1, v = 1$: Tanimoto

$u = 1/2, v = 1/2$: Dice

$u = 1, v = 0$: $s_{1,0}(X_a, X_b) = c/a$

Wann was?

- Topologische Features-Vektoren werden in der Regel mit Tanimoto-Verglichen
- Kosinus effizienter als Tanimoto
- Tversky-Koeffizient drückt Teilstrukturähnlichkeit aus